



郑州大学学报(理学版)
Journal of Zhengzhou University(Natural Science Edition)
ISSN 1671-6841,CN 41-1338/N

《郑州大学学报(理学版)》网络首发论文

题目: 基于改进 YOLO 的装甲目标毁伤状态估计方法
作者: 宋轩, 李新家, 徐旺旺, 余维
DOI: 10.13705/j.issn.1671-6841.2025068
收稿日期: 2025-06-26
网络首发日期: 2025-09-28
引用格式: 宋轩, 李新家, 徐旺旺, 余维. 基于改进 YOLO 的装甲目标毁伤状态估计方法[J/OL]. 郑州大学学报(理学版),
<https://doi.org/10.13705/j.issn.1671-6841.2025068>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进 YOLO 的装甲目标毁伤状态估计方法

宋 轩¹, 李新家¹, 徐旺旺¹, 余 维^{1,2}

(1. 郑州大学 网络空间安全学院 河南 郑州 450002;
2. 郑州市区块链与数据智能重点实验室 河南 郑州 450002)

摘要: 针对战场上装甲目标毁伤状态检测所面临的图片背景复杂、毁伤程度各异及毁伤特征多变等挑战,提出一种轻量级装甲目标毁伤状态评估方法——挤压-激励(squeeze-and-excitation, SE)与特征融合增强的 YOLO 模型。首先,通过在 Focus 模块中添加 SE 注意力机制,设计了 SE-Focus 特征提取模块,通过增强关键特征和减少信息冗余来提升模型在复杂环境下的适应性和检测效果。其次,融合加权跨尺度双向特征金字塔网络(bi-directional feature pyramid network, BiFPN)的多尺度特征融合优势与深度可分离卷积(depthwise separable convolution, DSConv)的高效计算特性,在保留 BiFPN 的优异跨尺度特征交互能力的同时,借助 DSConv 的特性降低模型复杂度与运算成本。最后,引入 Siou 损失函数,增强模型的鲁棒性及训练稳定性。在装甲目标毁伤坦克数据集上的实验结果表明,在参数数量不变的情况下,所提模型相比原模型 $mAP50$ 提高 1.8 个百分点,召回率提高 1.9 个百分点, $mAP50-95$ 提高 1.7 个百分点,验证了改进策略的有效性。

关键词: 毁伤检测; YOLO; Siou 损失函数; SE 注意力机制; BiFPN

中图分类号: TP391.4

文献标志码: A

DOI: 10.13705/j.issn.1671-6841.2025068

Damage State Estimation Method for Armored Targets Based on Improved YOLO

SONG Xuan¹, LI Xinjia¹, XU Wangwang¹, SHE Wei^{1,2}

(1. School of Cyber Science and Engineering, Zhengzhou University, Zhengzhou 450002, China;
2. Zhengzhou Key Laboratory of Blockchain and Data Intelligence, Zhengzhou 450002, China)

Abstract: A lightweight armored target damage state evaluation method, the squeeze-and-excitation (SE) and feature fusion enhanced YOLO model, was proposed to address the challenges of complex battlefield image backgrounds, varying damage levels, and dynamic damage characteristics in target damage state assessment. Firstly, a SE-Focus feature extraction module was designed by adding SE attention mechanism in the Focus module. By enhancing key features and reducing information redundancy, the adaptability and detection performance of the model in complex environments were improved. Secondly, the advantages of multi-scale feature fusion from the weighted bi-directional feature pyramid network (BiFPN) were integrated with the efficient computing characteristics of depthwise separable convolution (DSConv). While retaining the excellent cross scale feature interaction ability of BiFPN, the feature of DSConv was utilized to reduce model complexity and computational cost. Finally, the Siou loss function was introduced to enhance the model's robustness and training stability. Experimental results demonstrated that when tested on the damaged tank dataset of armored targets, a 1.8 percentage points improvement in $mAP50$, a 1.9 percentage points increase in recall rate, and a 1.7 percentage points rise in $mAP50-95$ were achieved by the proposed model compared to the original model while the same parameter

收稿日期: 2025-06-26

基金项目: 目标易损性评估全国重点实验室开放基金项目(YSX2024KFPG004)

第一作者: 宋轩(1971—), 男, 教授, 主要从事软件工程和信息安全研究, E-mail: songxuan@zzu.edu.cn.

通信作者: 余维(1977—), 男, 教授, 主要从事智能系统和区块链技术研究, E-mail: wshe@zzu.edu.cn.

quantity was maintained, which verified the effectiveness of the proposed improvements.

Key words: damage detection; YOLO; Siou loss function; SE attention mechanism; BiFPN

0 引言

在现代军事作战中,装甲车毁伤状态的快速准确识别对战场态势评估至关重要。计算机视觉、深度学习和无人机技术的发展为智能目标检测技术提供了新手段^[1],但装甲目标毁伤检测仍面临战场环境复杂、目标损毁程度各异且存在遮挡等挑战,传统高复杂度模型在移动平台上的高效运行受限。因此,设计兼顾精度的轻量化、高鲁棒性装甲目标毁伤检测模型,是军事智能化的重要研究方向。

目标检测方法根据是否生成候选框分为两阶段检测法(如 Faster RCNN^[2]、Mask RCNN^[3])和单阶段检测法(如 SSD^[4]、RetinaNet^[5]和 YOLO 系列^[6])。两阶段检测方法精度较高但速度慢,单阶段检测方法结构简单、实时性强,应用更普及,但其在装甲目标毁伤检测中面临三类问题:1) 特征鉴别难题。传统卷积很难捕捉非刚性形变不规则特征,且战场烟雾、遮挡会大幅降低关键特征信噪比。石磊等^[7]和王晨露等^[8]通过注意力机制强化了损伤区域的语义表达,但在常规空间注意力易受背景干扰。2) 计算效率瓶颈。多尺度特征融合是处理目标尺寸多变的关键,张科等^[9]采用了 BiFPN^[10]结构实现多层特征信息融合,但存在重复上采样、下采样操作,导致大量的计算资源消耗于特征图尺度变换。庞玉东等^[11]和孟群康等^[12]引入 DSConv 尝试轻量化设计,但往往以牺牲小目标检测性能为代价,难以满足战场实时性要求。3) 定位精度缺陷。毁伤目标常呈现倾斜、堆叠等特殊姿态,传统 IoU 度量忽略边界框方向关系,导致定位偏差放大效应。Siou 损失函数^[13]引入角度约束可改善此问题,但现有方法在严重遮挡场景下的稳定性仍有待提升。

针对复杂场景下的装甲目标检测挑战,本文提出一种挤压-激励(squeeze-and-excitation, SE)与特征融合增强的 YOLO 模型,简称为 SDS-YOLO 模型。所提模型通过扩大感受野、融合局部与全局上下文信息以及优化特征融合,提升了装甲目标毁伤状态检测精度。主要贡献如下:1) 提出一种 SE-Focus 特征提取模块,通过通道级特征重标定与空间压缩的协同作用,增强关键特征并抑制冗余信息,实现毁伤区域特征的自适应强化。2) 将 DSConv 嵌入特征金字塔网络,提出了 DS-BiFPN 结构,在保持优异的

跨尺度特征交互能力的同时,降低了模型复杂度和计算开销。3) 提出一种基于 Siou 损失函数的目标预测框与真实框的方向匹配方法,提高了模型的收敛速度、检测鲁棒性和训练稳定性。

1 YOLOv11

虽然 YOLOv12 是最新的目标检测算法,但 YOLOv11 的架构稳定性和成熟度已在实际应用中得到了充分验证,其兼容性表现优异;而 YOLOv12 引入的动态训练策略在复杂战场环境下可能带来不可预测的计算波动。在综合考量模型精度、推理速度与计算资源消耗三者的平衡关系后,选择 YOLOv11 作为基础模型进行改进。

YOLOv11 模型由骨干特征提取(backbone)、特征融合(neck)、目标预测(head)构成,其在通用目标检测中实现了精度-速度平衡,但针对军事装甲目标毁伤检测存在三大短板:backbone 对毁伤关键特征关注度低,复杂背景下易丢失有效信息;neck 依赖特征金字塔网络(feature pyramid network, FPN)^[14]和路径聚合网络(path aggregation network, PAN)^[15]进行多尺度融合,导致装甲目标毁伤跨尺度特征交互效率低,多类型毁伤检测精度受限;head 采用的传统损失函数对装甲目标倾斜姿态、不规则毁伤边界适应性差,定位误差明显。

2 SDS-YOLO 模型

本文提出的 SDS-YOLO 模型旨在提供更加精准和可靠的装甲目标毁伤识别解决方案,以适应复杂的战场环境。SDS-YOLO 网络结构见图 1,其中空间金字塔池化-快速版(spatial pyramid pooling-fast, SPPF)的作用是减少计算量并提高运行速度。

2.1 SE-Focus 特征提取模块

YOLO 中的 Focus 模块通过切片操作将空间信息转为通道信息,实现高效下采样并保留关键空间信息,适用于低层次特征提取。但其无法区分重要特征,导致特征利用效率低,在复杂场景或背景干扰多时表现不足,还可能因保留冗余信息而增加计算负担。为解决 Focus 模块存在的问题,在 Focus 模块中引入 SE 注意力机制^[16],并提出了 SE-Focus 模块。该模块可以在保持高效空间压缩能力的同时,




图 1 SDS-YOLO 网络结构

Figure 1 SDS-YOLO network structure

利用通道注意力机制动态调整特征权重,增强重要特征并抑制冗余信息,从而提升模型对复杂场景的适应能力和检测性能。SE-Focus 模块结构示意图见图 2。




图 2 SE-Focus 模块结构示意图

Figure 2 Schematic diagram of SE-Focus module structure

SE 注意力机制是一种通道注意力机制,通过学习通道之间的依赖关系,动态调整特征图中每个通道的权重,从而增强重要特征并抑制不重要特征。假设输入特征图为 X ,其形状为 (B, C, H, W) , B 为 batch size, C 为通道数, H 为高度, W 为宽度,则 SE 注意力机制的计算过程可以概括为以下步骤。

1) squeeze 操作(全局信息压缩):将每个通道的空间信息(高度和宽度)压缩为一个全局描述符。对通道进行全局平均池化(GAP),将每个通道的 $H \times W$ 特征图压缩为一个标量值。公式可表示为

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c(i, j), \quad (1)$$

其中: z_c 是第 c 个通道的压缩结果; $x_c(i, j)$ 是第 c 个

通道在位置 (i, j) 的特征值;输出 z 的形状为 $(B, C, 1, 1)$ 。

2) excitation 操作(通道依赖关系建模):学习通道之间的依赖关系,生成每个通道的权重,通过两个全连接层和非线性激活函数 ReLU 建模通道之间的关系。公式可表示为

$$a_c = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot z)), \quad (2)$$

其中: a_c 是在 excitation 过程中计算得到的相应权重; z 是 squeeze 步骤的输出; W_1 是第 1 个全连接层的权重矩阵,将通道数从 C 降维到 C/r (r 是降维比率); W_2 是第 2 个全连接层的权重矩阵,将通道数从 C/r 恢复到 C ; σ 是 Sigmoid 函数,将权重归一化到 $[0, 1]$ 。

3) 特征加权:将学习到的通道权重应用于原始特征图,增强重要特征并抑制不重要特征,将通道权重 a_c 与输入特征图 X 逐通道相乘。公式可表示为

$$\tilde{x}_c = a_c \cdot x_c, \quad (3)$$

其中: $\tilde{x}_c$ 是加权后的第 c 个通道特征图; x_c 是输入到 SE 模块的特征图中第 c 个通道的特征。

2.2 DS-BiFPN 特征融合模块

在传统装甲目标毁伤检测中,PANet 和 BiFPN 的结构见图 3。其中,PANet 的结构如图 3(a)所示,其静态结构无法动态适应多尺度毁伤特征变化,且通道维度未区分噪声与特征,导致算力浪费和精度下降。BiFPN 的结构如图 3(b)所示,该结构虽然提升了特征交互效率,但其标准 3×3 卷积计算量达 10^9 级别,难以满足终端轻量化需求,且缺乏细粒度特征增强机制,导致小尺度毁伤特征易被覆盖,出现弹孔漏检和裂纹模糊等问题。




图 3 PANet 和 BiFPN 的结构

Figure 3 Structure of PANet and BiFPN

针对传统方法的缺陷,提出新型颈部网络结构 DS-BiFPN,其在保留 BiFPN 多尺度特征融合高效性

与灵活性的同时,结合 DSConv 以降低模型的复杂度和计算需求,尤其适用于资源受限的应用场景。

BiFPN 通过双向路径实现多尺度特征融合,同时通过剪枝冗余节点优化结构,并在同层级节点间新增特征传递路径;其在不增加计算量的前提下,借助加权融合机制自适应学习特征重要性,提升特征利用效率,且在特征融合过程中,通过结构化加权融合机制融合同一层级的原始输入、中间特征及相邻层的输出特征,实现了同层级多源特征的最优整合。以 BiFPN 第 i 层特征融合过程为例,其计算分为自顶向下和自底向上两个阶段,每个阶段生成不同的特征值。

1) 自顶向下路径(top-down)中间特征生成,其计算公式为

$$P_i^{td} = \text{Conv}\left(\frac{w_1 \cdot P_i^{in} + w_2 \cdot \text{Resize}(P_{i+1}^{td})}{w_1 + w_2 + \epsilon}\right), \quad (4)$$

其中:Conv 是卷积操作; P_i^{in} 是第 i 层原始输入特征; P_{i+1}^{td} 是上一层自顶向下路径输出的下采样特征; w_1, w_2 为可学习权重,通过 ReLU 激活函数确保非负性($w_1, w_2 \geq 0$);Resize 操作调整特征分辨率以匹配当前层;分母引入极小值 $\epsilon = 0.0001$ 以防止数值不稳定。

2) 自底向上路径(bottom-up)输出特征生成,其计算公式为

$$P_i^{out} = \text{Conv}\left(\frac{w'_1 \cdot P_i^{in} + w'_2 \cdot P_i^{td} + w'_3 \cdot \text{Resize}(P_{i-1}^{out})}{w'_1 + w'_2 + w'_3 + \epsilon}\right), \quad (5)$$

其中: P_i^{td} 是当前层中间特征; P_{i-1}^{out} 是下一层自底向上路径输出的上采样特征; w'_1, w'_2, w'_3 为可学习权重,同样通过 ReLU 约束非负性。

以 DSConv 替换 BiFPN 的标准卷积,解决其计算成本高的问题。DSConv 是一种高效卷积方式,将标准卷积拆分为两步:先通过深度卷积对输入特征图的每个通道单独卷积以提取局部空间特征,再用逐点卷积实现通道间信息融合并调整通道数,其流程如下。

1) 逐通道卷积:对输入特征图的每个通道单独进行卷积操作,使用不同卷积核提取各通道的独特特征。此过程能避免通道间信息干扰,让模型聚焦通道内的细节特征提取。若输入特征图通道数为 C ,卷积核大小为 $K \times K$,则逐通道卷积的参数量为 $C \times K \times K$,有

$$\text{Input}_c(i, j) = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} \text{Input}_c(i+m, j+n), \quad (6)$$

$$\text{Output}_c(i, j) = \text{Input}_c(i, j) \cdot \text{Weight}_c(m, n), \quad (7)$$

其中: Input_c 是输入特征图的第 c 个通道; Weight_c 是第 c 个通道的 $K \times K$ 卷积核权重; (i, j) 是输出特征图的空间位置。

2) 逐点卷积:通过 1×1 卷积核,对逐通道卷积输出的多通道特征进行跨通道融合,在低计算量下整合不同通道的信息,实现特征的跨通道交互。若输出通道数也为 C ,参数量为 $C \times C \times 1 \times 1$,则

$$\text{Output}_c(i, j) = \sum_{c=1}^C \text{Input}_c(i, j) \cdot \text{Weight}_{c', c}. \quad (8)$$

相较于标准卷积,DSConv 在大幅降低参数量和计算量的同时保留了空间和通道特征提取能力,是实现模型轻量化的关键。

2.3 SIOU 损失函数

YOLOv11 默认的 CIoU 损失函数^[17]虽然考虑中心点距离、重叠面积及纵横比等,但未考量方向匹配度,导致收敛慢,检测性能受到影响。针对此问题,提出一种基于 SIOU 的方向匹配方法,通过显式建模方向关系减少空间偏差以引导快速收敛,联合优化方向对齐与角度成本以抑制无效变形、增强复杂场景泛化能力,解耦方向匹配与传统指标以平滑梯度、降低训练震荡并提升噪声数据下的稳健性。SIOU 损失函数由以下四个部分组成。

1) 角度损失(angle cost):用于衡量预测框与真实框之间的方向偏差,能够通过惩罚方向偏差,加速模型收敛。角度损失示例见图 4,其计算公式为

$$\Delta = 1 - 2\sin^2\left(\arcsin \frac{c_h}{s}\right) - \frac{\pi}{4}, \quad (9)$$

其中: c_h 是预测框与真实框中心点的高度差; s 是预测框与真实框中心点之间的距离。




图 4 角度损失示例

Figure 4 Angle cost examples

2) 距离损失(distance cost):用于衡量预测框与真实框中心点之间的距离,通过动态调整距离损失的权重,增强模型对中心点偏差的敏感性。距离损失示例见图 5,其计算公式为

$$\Delta = \sum_{t=x, y} (1 - e^{-\gamma \rho_t}), \quad (10)$$

$$\rho_x = \left(\frac{b_{cx}^{gt} - b_{cx}}{c_w}\right)^2, \quad (11)$$

$$\rho_y = \left(\frac{b_{cy}^{gt} - b_{cy}}{c_h} \right)^2, \quad (12)$$

其中:式(11)为宽度方向的归一化距离差;式(12)为高度方向的归一化距离差; $(b_{cx}^{gt}, b_{cy}^{gt})$ 为真实框中心坐标; (b_{cx}, b_{cy}) 为预测框中心坐标; $\gamma = 2 - A$ 是角度损失的调整因子。




图 5 距离损失示例

Figure 5 Distance cost examples

3) 形状损失 (shape loss): 用于衡量预测框与真实框在宽度和高度上的差异,通过控制形状损失的权重,增强模型对目标形状的建模能力,其计算公式为

$$\Omega = \sum_{t \in \{w, h\}} (1 - e^{-w_t})^\theta, \quad (13)$$

$$w_w = \frac{|w_c - w^{gt}|}{\max(w_c, w^{gt})}, \quad (14)$$

$$w_h = \frac{|h_c - h^{gt}|}{\max(h_c, h^{gt})}, \quad (15)$$

其中:式(13)为宽度的归一化差异;式(14)为高度的归一化差异; w_c 为预测框的宽度; w^{gt} 为真实框的宽度; h_c 为预测框的高度; h^{gt} 为真实框的高度; θ 为形状损失的调整因子,取值范围为 $[2, 6]$ 。

4) IoU 损失 (IoU loss): 用于衡量预测框与真实框之间的重叠区域,可直接衡量预测框与真实框的重叠程度,其计算公式为

$$L_{IoU} = \frac{(b \cap b^{gt})}{(b \cup b^{gt})}, \quad (16)$$

其中: b 为预测框; b^{gt} 为真实框。

综合上述四个部分,SIoU 损失函数可表示为

$$L_{SIoU} = 1 - L_{IoU} + \frac{\Delta + \Omega}{2}, \quad (17)$$

其中: Δ 为距离损失项; Ω 为形状损失项。

3 实验数据与评价指标

3.1 实验数据集

实验数据中,坦克相关图像的获取主要通过百度图片、谷歌图片这两个主流搜索引擎完成。具体检索过程为:以坦克、毁伤坦克等为核心关键词进行

检索,筛选范围限定为公开可下载的网络图像,涵盖不同国家、不同型号、不同场景下的坦克图像,最终从检索结果中人工剔除重复、模糊及非坦克主体的图像,保留 1 079 张有效原始图像。部分数据集样本示例如图 6 所示。

为提升数据多样性和模型泛化能力,对原始数据集进行随机旋转($\pm 30^\circ$)、翻转、亮度/对比度调整、高斯噪声添加及尺度变换等增强处理,使训练集扩展至 3 237 张,既保证样本多样性又兼顾操作可行性,为模型训练提供充分的数据支撑。



图 6 数据集样本示例

Figure 6 Sample examples of dataset

实验使用 LabelImg 工具对所得图像进行标注,涵盖了 5 种不同类别的坦克部件:炮管 (gun_barrel)、坦克 (tank)、履带 (track)、毁伤履带 (track_damage) 以及毁伤坦克 (tank_damage)。所有图片均采用数据增强技术调整至 640×640 分辨率,并保存为 JPG 格式。随后,将该数据集按照 8:1:1 的比例随机划分为训练集 (2 589 张)、验证集 (324 张) 和测试集 (324 张),以支持模型的训练、评估及最终性能验证。

3.2 实验环境

实验环境配置如下:操作系统采用 Windows 10 64 位,搭配 AMD Ryzen 7 7840H 的 CPU 和 RTX 4060 GPU (配备 8 GB 显存),16 GB 内存。使用 Python 3.8.20 作为编程语言,结合 PyTorch 2.4.1 + cu121 深度学习框架进行模型的训练与验证,同时采用 Conda 22.11.1 来管理实验所需的软件包和依赖项,确保了实验环境的稳定性和可复现性。

为确保实验结果具有良好的可比性、有效性和公平性,所有实验在训练过程中均采用统一且严格的超参数设置,训练轮数为 200 轮,批次大小为 16,输入图像统一缩放至 640×640 像素并归一化,采用动量为 0.937 且引入权重衰减的 SGD 优化器,采用初始学习率为 0.01 且最终学习率为 0.0001 的线性衰减策略,以及统一的数据增强、权重初始化和正则化方法等,以消除非目标变量对实验结果的干扰。

3.3 评价指标

采用以下指标评估模型性能。

1) 精确率(Precision):表示模型预测为正类的样本中实际为正类的比例,其计算公式为

Precision = TP / (TP + FP), (18)

其中:TP表示预测为正类且实际为正类的样本数;FP表示预测为正类但实际为负类的样本数。

2) 召回率(Recall):表示实际为正类的样本中被模型正确预测为正类的比例,其计算公式为

Recall = TP / (TP + FN), (19)

其中:FN表示预测为负类但实际为正类的样本数。

3) 平均精度(AP):通过计算每个类别的精确率-召回率曲线下的面积来衡量模型在不同阈值下的平均精度,其计算公式为

AP = \int_0^1 Precision(Recall) d(Recall). (20)

4) 平均精度均值(mAP):所有类别的平均精度的均值,其计算公式为

mAP = \frac{1}{N} \sum_{i=1}^N AP_i, (21)

其中:N表示类别总数。使用mAP50表示当预测框与真实框的IoU阈值为0.5时的mAP;使用mAP50-95表示IoU阈值为[0.50,0.95]且步长为0.05时的mAP。

除上述4个评价指标外,其他评价指标还包括帧率和参数量。其中,帧率表示模型每秒能够处理的图像数量,用于衡量模型的检测速度;参数量表示模型的卷积层、全连接层、输出层等包含的参数数量,反映了模型的存储需求和计算复杂度。

4 实验结果分析

4.1 消融实验

为验证本文所提出的SDS-YOLO模型的有效性,在自行收集的装甲目标数据集上开展了7组消融实验。核心思路是以YOLOv11模型作为基础框架,依次引入不同的改进模块,并通过系统性组合与对比,深入评估每个新增模块对模型整体性能的影响,有助于识别各模块对检测精度、速度及稳定性等方面的贡献度,消融实验结果如表1所示。

表1 消融实验结果

Table 1 Results of ablation experiment

编号	DS-BiFPN	SE-Focus	SIoU	mAP50/%	mAP50-95/%	参数量/10 ⁶	帧率/(f·s ⁻¹)
1				89.5	68.2	2.6	186
2	✓			90.8	70.5	2.6	173
3		✓		90.6	70.6	2.6	180
4			✓	90.6	70.5	2.6	186
5	✓		✓	90.9	70.5	2.6	174
6		✓	✓	91.2	68.7	2.6	177
7	✓	✓	✓	91.3	69.9	2.6	177

通过消融实验分析各模块影响,其中帧率通过相同环境下12次测试及剔除极值后取10次均值来保证结果稳定可靠。由表1可以看出,在装甲目标毁伤坦克数据集上进行测试时,SDS-YOLO模型(编号7)在参数数量不变的情况下,相比原模型(编号1)mAP50提高1.8个百分点,mAP50-95提高1.7个百分点,验证了改进策略的有效性。

4.2 对比实验

在目标检测模型性能评估中,将所提出的SDS-YOLO模型与Faster RCNN^[2]、SSD^[4]、YOLO系列^[6]以及经本文改进策略优化的YOLOv8变体等展开对比,不同模型的对比实验结果见表2。可以看出,在检测精度方面,SDS-YOLO模型的mAP50值优于其

他所有模型;YOLOv3不仅精度最低,参数量更是同系列其他模型的数倍,效率欠佳,在计算资源利用层面劣势显著;YOLOv8n与YOLOv10n在推理速度、参数量及检测精度上表现出高度一致;而经本文方法优化的YOLOv8变体,在检测精度、召回率上均较原始版本有显著提升,充分印证了本文优化策略在YOLO系列模型中的广泛适用性与有效性。在检测速度方面,SDS-YOLO模型实现了精度与效率的良好平衡。YOLO系列和SSD的单阶段架构在检测精度、参数量和召回率等方面显著优于Faster RCNN的两阶段架构。通过引入SE-Focus和DS-BiFPN实现特征权重动态调整,虽使处理速度较YOLOv11n略有降低,但提升了复杂背景下的检测性能,且在参

数量保持不变的情况下,SDS-YOLO 模型的 $mAP50$ 检测精度与计算效率的协同优化,满足战场环境下提升 1.8 个百分点、召回率提升 1.9 个百分点,达到对实时目标监测的需求。

表 2 不同模型的对比实验结果
Table 2 Comparative experimental results of different models

模型	Precision/%	Recall/%	$mAP50$ /%	参数量/ 10^6	帧率/($f \cdot s^{-1}$)
Faster RCNN	73.6	74.2	77.5	41.0	89
SSD	81.2	77.0	81.1	24.7	55
YOLOv3-tiny	67.0	68.9	69.3	8.7	124
YOLOv5n	79.5	84.6	85.2	1.8	220
YOLOv8n	85.9	85.5	90.1	3.0	151
YOLOv8n+SE-Focus	83.9	87.6	90.3	3.0	140
YOLOv8n+SIoU	84.2	86.1	90.7	3.0	140
YOLOv8n+SE-Focus+SIoU	85.1	86.4	91.0	3.0	148
YOLOv10n	84.4	84.7	90.1	2.7	155
YOLOv11n	85.2	85.5	89.5	2.6	186
YOLOv12n	85.6	86.4	89.9	2.6	184
SDS-YOLO	85.7	87.4	91.3	2.6	177

4.3 性能分析

在装甲目标坦克数据集 5 个类别上 SDS-YOLO 模型性能分析结果如表 3 所示。可以看出,各类别的 $mAP50$ 均超过 85%;模型对坦克的检测性能最优,毁伤履带的精确率最高但综合阈值下表现较弱,毁伤坦克的召回率最高但精确率最低;整体精确率为 84.4%,召回率为 87.4%, $mAP50$ 为 91.3%, $mAP50-95$ 为 69.9%,表明整体检测效果良好。

表 3 模型性能分析结果
Table 3 Model performance analysis results

类别	Precision	Recall	$mAP50$	$mAP50-95$
炮管	86.4	80.0	85.0	61.3
坦克	90.0	94.2	96.7	87.4
毁伤坦克	65.4	94.6	89.3	74.7
履带	87.9	84.8	92.3	72.5
毁伤履带	92.4	83.4	93.2	53.7
整体	84.4	87.4	91.3	69.9

5 结语

本文针对复杂战场环境下装甲目标检测任务中存在的背景干扰、毁伤程度差异等挑战,提出了一种改进型 SDS-YOLO 检测模型。该模型针对特征提取过程中的关键特征弱化和噪声干扰问题,创新性地设计了基于通道注意力机制的 SE-Focus 模块,通过特征重标定策略实现了关键特征的动态增强与噪声抑制,有效提升了特征提取的鲁棒性。在网络结构

设计方面,为了消除传统多尺度特征融合计算效率低的影响,提出了 DS-BiFPN 结构,在保持优异特征融合能力的同时显著提升了模型的计算效率。此外,针对边界框回归中角度偏差影响定位精度的问题,将 SiIoU 度量准则引入装甲目标检测领域。实验数据表明,该模型在复杂战场环境下的军事目标检测任务中展现出优越的性能。在后续研究中将进一步展开针对特殊损伤模式的优化,通过生成对抗网络增强数据多样性,提升模型对非典型损伤形态的泛化能力,并结合形变卷积改进定位方法,实现严苛定位标准下的稳定检测。

参考文献:

[1] 余维,岳瀚,田钊,等. 基于 D3QN 的火力方案优选方法[J]. 火力与指挥控制, 2024, 49(8): 166-174.
SHE W, YUE H, TIAN Z, et al. Optimization selection method of fire plan based on D3QN[J]. Fire control & command control, 2024, 49(8): 166-174.
[2] 郭子豪,董乐乐,曲志坚. 基于改进 Faster RCNN 的节肢动物目标检测方法[J]. 计算机应用, 2023, 43(1): 88-97.
GUO Z H, DONG L L, QU Z J. Arthropod object detection method based on improved Faster RCNN[J]. Journal of computer applications, 2023, 43(1): 88-97.
[3] LIU Y, WANG R, SHAN S, et al. Deep learning for mask R-CNN based object detection and instance segmentation in remote sensing imagery [J]. ISPRS journal of photogrammetry and remote sensing, 2020, 162: 154-173.
[4] ZHANG S F, CHI C, YAO Y Q, et al. Bridging the gap

- between anchor-based and anchor-free detection via adaptive training sample selection [C] //IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway:IEEE Press, 2020: 9756–9765.
- [5] 王雨生, 顾玉宛, 封晓晨, 等. 基于姿态估计的安全帽佩戴检测方法研究[J]. 计算机应用研究, 2021, 38(3): 937–940, 945.
WANG Y S, GU Y W, FENG X C, et al. Research on detection method of helmet wearing based on attitude estimation[J]. Application research of computers, 2021, 38(3): 937–940, 945.
- [6] REDMON J, FARHADI A. YOLOv4: optimal speed and accuracy of object detection [J]. Journal of computer vision and pattern recognition, 2020, 38(5): 1023–1034.
- [7] 石磊, 王天宝, 孟彩霞, 等. 复杂场景下的人体姿态估计算法[J]. 郑州大学学报(理学版), 2025, 57(4): 1–7.
SHI L, WANG T B, MENG C X, et al. Multi-person pose estimation algorithm in complex scenes[J]. Journal of Zhengzhou university (natural science edition), 2025, 57(4): 1–7.
- [8] 王晨露, 陈立家, 李坤, 等. 局部特征表征的 6D 位姿估计算法[J]. 计算机应用研究, 2022, 39(12): 3808–3814.
WANG C L, CHEN L J, LI S, et al. 6D pose estimation algorithm for local feature representation[J]. Application research of computers, 2022, 39(12): 3808–3814.
- [9] 张科, 彭远刚, 王跃明, 等. 基于改进 YOLOv8 的试管及液位识别算法[J]. 计算机应用, 2024, 44(S2): 296–301.
ZHANG K, PENG Y G, WANG Y M, et al. Test tube and liquid level recognition algorithm based on improved YOLOv8[J]. Journal of computer applications, 2024, 44(S2): 296–301.
- [10] TAN M X, PANG R M, LE Q V. EfficientDet: scalable and efficient object detection[C] //IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Press, 2020: 10778–10787.
- [11] 庞玉东, 李志星, 刘伟杰, 等. 基于改进实时检测 Transformer 的塔机上俯视场景小目标检测模型[J]. 计算机应用, 2024, 44(12): 3922–3929.
PANG Y D, LI Z X, LIU W J, et al. Small target detection model in overlooking scenes on tower cranes based on improved real-time detection Transformer[J]. Journal of computer applications, 2024, 44(12): 3922–3929.
- [12] 孟群康, 李强, 赵峰, 等. 面向小型边缘计算的深度可分离神经网络模型与硬件加速器设计[J]. 计算机应用研究, 2024, 41(3): 861–865, 879.
MENG Q K, LI Q, ZHAO F, et al. Design of depthwise separable neural network models and hardware accelerator for small-scale edge computing[J]. Application research of computers, 2024, 41(3): 861–865, 879.
- [13] GEVORGYAN Z. SIoU loss: more powerful learning for bounding box regression[EB/OL]. (2022-05-25)[2025-02-18]. <https://arxiv.org/pdf/2205.12740>.
- [14] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection [C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Press, 2017: 936–944.
- [15] LIU S, QI L, QIN H F, et al. Path aggregation network for instance segmentation[C] //IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Press, 2018: 8759–8768.
- [16] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C] //IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway:IEEE Press, 2018: 7132–7141.
- [17] ZHENG Z H, WANG P, LIU W, et al. Distance-IoU loss: faster and better learning for bounding box regression [C] //Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2020: 12993–13000.