

学校代码： 10264
研究生学号： M200701412

上海海洋大学

硕士学位论文

（国家自然科学基金项目资助，编号：41871325）

题 目： 基于深度学习的海陆目标分类研究
英文题目： Research on Classification of Land and
 Sea Targets Based on Deep Learning
专 业： 计算机科学与技术
研究方向： 深度学习遥感图像处理
姓 名： 钟宏正
指导老师： 洪中华教授

二〇二三年五月九日

基于深度学习的海陆目标分类研究

摘要

随着应急救援事业的不断发展，建筑物和船舶作为陆地和海洋中最重要的目标之一。建筑物地震损毁分类和船舶目标分类在应急管理中具有极为重要的意义。在地震灾害中，快速、准确地评估建筑物损毁情况可以帮助救援人员有针对性地制定救援计划，提高救援效率和成功率。而海面船舶目标分类可以帮助应急管理部门实现对海上交通情况的监控，及时发现海上交通事故，提高应急响应速度和水平。

在地震灾害中，建筑物是最容易受到影响的地物之一，其损毁情况直接关系到灾害救援的进展和工作效率。传统的人工调查方法受限于人力、时间和地点等因素，难以快速准确地获取灾区内的建筑物损毁情况。基于深度学习的建筑物地震损毁分类方法可以快速提供详细的灾情信息，为灾后救援和重建提供有力的支持。在建筑物地震损毁评估研究中尽管已经提出了许多方法，但大多数方法都是将受损建筑分为倒塌和未倒塌两类，这不足以满足实际的精细化评估需求。为了解决这个问题，本研究提出了一个新型的地震建筑损毁分类网络（EBDC-Net），用于灾后建筑物损毁的精细化评估。该网络由一个建筑物损毁特征编码器模块和一个建筑物损毁分类模块构成。特征提取编码器模块用于提取影像中建筑物损毁的语义信息，并引入空间注意力机制聚集影像中分散的损毁特征，增强网络的特征表达能力，提高网络对不同损毁等级建筑物的区分能力。而建筑物损毁分类网络则结合全局和上下文特征提取模块来增强网络对全局特征和局部特征关系的探索能力，提升网络对建筑物损毁等级分类的准确性。在鲁甸和玉树地震建筑物损毁数据集上对该网络的性能进行了评估，并在漾濞地震数据集上进行了大规模的建筑物损毁评估。实验结果表明，该方法可以快速有效地对不同损毁程度的建筑物进行分类。当建筑物的损毁程度被分为两类、三类和四类时，总体分类准确率分别为 94.44%、85.53%和 77.49%。

在海事领域中，船舶目标分类是实现海上安全、资源开发和环境检测的重要基础。在海面船舶分类研究中尽管已经提出了许多分类方法，但是，这些方法大

多数依赖单一数据源进行分类，这不足以满足全天时、全天候对船舶目标进行分类的需要。同时，单一数据源也会影响船舶分类的准确性。本研究针对复杂海况下仅使用单源数据进行船舶分类时精度不高的问题，提出了一种基于多源数据的自适应加权决策级融合船舶分类方法。该方法包含多源影像生成模块、单源数据船舶分类模块以及多源数据决策级融合分类模块。多源影像生成模块基于 CycleGAN 网络构建了 OPT-SAR 影像转换模型，将光学影像转为匹配的 SAR 影像，建立了一个多源遥感影像船舶分类数据集。单源数据船舶分类模块引入高斯模型对 YOLOv4 模型中预测框的坐标进行建模，提高预测框的可靠性。并分别从 SAR 和光学影像中识别不同类型的船舶。在多源数据决策级融合分类模块中构建了自适应加权的决策级融合分类方法对不同数据源的分类结果进行决策级融合判定，提升复杂海况下船舶分类的精度。与目前最先进的决策级融合分类方法相比，本文中提出的方法取得了最高的分类精度。与仅使用 SAR 和光学影像相比，船舶分类的精度分别提高了 10.57%和 2.61%。即使在复杂的海况下，本文提出的方法仍然表现出良好的船舶分类识别能力。

关键词：建筑物损毁分类，船舶分类，遥感影像，数据融合，深度学习

Research on Classification of Land and Sea Targets Based on Deep Learning

ABSTRACT

With the continuous development of emergency rescue, buildings and ships are the two most important targets in land and sea, and the classification of building earthquake damage and ship target classification plays an important role in emergency management. In earthquake disasters, rapid and accurate assessment of building damage can help rescuers make targeted rescue plans, improve rescue efficiency and success rate; and sea ship target classification can help emergency management departments monitor maritime traffic conditions, timely detection of marine traffic accidents, and improve the speed and level of emergency response.

In earthquake disasters, buildings are one of the most vulnerable ground features, and their damage is directly related to the progress and work efficiency of disaster relief. The traditional manual survey method is limited by factors such as manpower, time and location, and it is difficult to quickly and accurately obtain the damage of buildings in the disaster area. The earthquake damage classification of buildings based on deep learning can quickly provide detailed disaster information and provide strong support for post-disaster rescue and reconstruction. Although many methods have been proposed in the study of seismic damage assessment of buildings, most of them divide damaged buildings into two categories—intact and damaged—which is insufficient to meet practical needs. To address this issue, this study presents a novel convolutional neural network—namely, the earthquake building damage classification net (EBDC-Net)—for assessment of building damage. The proposed network comprises a feature building damage feature extraction encoder module and a damage classification module. The feature extraction encoder module is employed to extract semantic information on building damage, and introduce a spatial attention mechanism to gather scattered damage features in the image, enhance the feature expression ability of network, and improve the ability to distinguish between different damage levels. While the classification module combines the global

and contextual feature extraction modules to enhance the network's ability to explore the relationship between global features and local features, and improves the accuracy of the network in classifying building damage levels. The performance of EBDC-Net was evaluated on the Ludian and Yushu earthquake building damage datasets, and a large-scale damage assessment was performed on the Yangbi earthquake dataset. The results of the experiments indicate that this approach can quickly and accurately classify buildings with different damage levels. The overall classification accuracy was 94.44%, 85.53%, and 77.49% when the damage to the buildings was divided into two, three, and four categories, respectively.

In the maritime field, ship target classification is an important basis for maritime safety, resource development and environmental detection. Although various ship classification methods have been proposed during the past years, most of them are developed based on single source data, which is not enough to meet the needs of all-time and all-weather ship classification. At the same time, only use single data source will also affect the accuracy of ship classification. This study proposes an adaptive weighted decision-level fusion ship classification method based on multi-source data to solve the problem that only a single data source is used and the accuracy of ship classification is not high under complex sea conditions. The method includes a multi-source image generation module, a single-source data ship classification module and a multi-source data decision-level fusion classification module. Aiming at the problem of low accuracy of ship recognition using single source data, this paper proposes a novel ship recognition method using multi-source remote sensing images based on improved YOLOv4 and adaptive weighted decision level fusion. The multi-source image generation module builds an OPT-SAR image translation model based on the CycleGAN network, translate optical images into matching SAR images, and establishes a multi-source remote sensing image ship classification dataset. The single-source data ship classification module introduces a Gaussian model to model the coordinates of the prediction box in the YOLOv4 model to improve the reliability of the prediction box. And identify different types of ships from SAR and optical images respectively. In the multi-source data decision-level fusion classification module, an adaptive weighted decision-level fusion classification method is constructed to perform decision-level fusion judgment on the classification results of different data sources, and improve the accuracy of ship

classification under complex sea conditions. Compared with the state-of-the-art decision-level fusion classification methods; the proposed method in this study obtains the best accuracy; compared with only the SAR and optical images are used, the accuracy is improved 10.57% and 2.61%, respectively; Even under complex sea conditions, the method proposed still shows the good ability for ship classification.

KEY WORDS: building damage classification, ship classification, remote sensing image, data fusion, deep learning

目 录

第 1 章 引言.....	1
1.1 研究目的及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于深度学习的陆地建筑物损毁分类研究	2
1.2.2 基于深度学习的海面船舶目标分类研究	3
1.3 主要研究内容.....	6
第 2 章 基于 EBDC-Net 网络的建筑物地震损毁分类	9
2.1 EBDC-Net 建筑物地震损毁分类网络.....	9
2.1.1 特征提取编码器模块.....	9
2.1.2 建筑物损毁分类模块.....	11
2.2 建筑物地震损毁分类数据集	13
2.3 实验结果与分析.....	15
2.3.1 实验设置.....	15
2.3.2 不同基线模型建筑物损毁分类精度比较	17
2.3.3 消融实验结果.....	18
2.3.4 不同建筑物损毁分类方法分类精度比较	20
2.3.5 历史地震数据在未来地震中对建筑物损毁评估的作用	22
2.4 本章小结.....	24
第 3 章 基于 YOLOv4 和多源数据融合的船舶目标分类	26
3.1 OPT-SAR 影像转换模型	26
3.2 基于 YOLOv4 的船舶分类算法	30
3.3 基于自适应加权的多源决策级融合分类算法	32
3.4 实验数据.....	34
3.5 实验结果与分析.....	35
3.5.1 OPT-SAR 转换模型影像生成结果	35
3.5.2 单源数据船舶分类结果.....	37
3.5.3 不同决策级融合方法分类结果比较.....	39
3.5.4 多源数据对船舶分类精度的影响.....	41
3.5.5 不同海况对船舶分类精度的影响.....	42
3.6 本章小结.....	44
第 4 章 总结与展望	46
参考文献.....	48

第1章 引言

1.1 研究目的及意义

建筑物和船舶分别是陆地和海洋上两种重要的目标，建筑物地震损毁分类和海面船舶分类在应急管理具有重要的意义。在地震灾害中，及时准确地评估建筑物的损毁情况对于制定救援计划、分配救援资源以及指导灾后重建都有至关重要的作用。在海上，船舶目标分类可以帮助应急管理人员及时掌握海上交通情况，了解船只类型和数量，实现对海面船舶的实时监测和预警，减少海上安全事故的发生。建筑物地震损毁分类和海面船舶目标分类能够帮助应急管理部门制定科学、有效的应急预案，提高应急管理的效率和应对能力。

如今遥感技术在测绘、监测等很多领域中得到了广泛的应用。遥感影像具有数据量大、覆盖面广、空间尺寸大、抗干扰性强等特点。随着技术的不断发展，高分辨率的遥感影像具有更为详细的信息和更高的精度，能够为建筑物地震灾害损毁评估和船舶目标分类识别等提供技术支持。在海面船舶目标分类中，高分辨率的遥感影像可以实现对不同类型船舶的精准区分，从而为海上交通管理提供更好的支持。

地震是一种破坏性极强的自然灾害，它可以对建筑物造成严重的损毁。地震产生的振动会导致建筑物的结构发生变形和破坏，甚至导致建筑物整体倒塌。快速、准确地评估建筑物的损毁情况对促进灾害救援和重建工作开展具有重要的意义。传统的人工现场调查方法可以对受损建筑物进行全面检查，得出可靠、准确的损毁评估结果。然而，该方法工作量大、效率低、成本高^[1]。通常还会受到灾区通行条件的影响而无法到达灾害发生现场进行评估。在建筑物地震灾害损毁评估中，利用高分辨率遥感影像可以帮助救援人员快速、准确地识别和定位建筑物的损毁情况，以指导后续的救援和重建工作，特别是对于难以进行实地调查的地震灾区尤为重要^[2]。

船舶作为最重要的海洋目标之一，它们在海上运输和海洋监管方面发挥着十分重要的作用。因此，船舶分类识别对提高海上安全管理水平和海上应急救援具有重要的意义。不同的遥感卫星传感器在不同的空间、时间、光谱和分辨率上获取信息。对于海面船舶目标的分类识别，单个传感器提供的信息不完整和不精确。将不同的传感器数据以不同的方式结合起来有助于提高对不同类别船舶的区分能力。通用融合技术已经在物体的检测、物体识别分类、医学图像处理等各个领域得到了很好的发展。尽管发展迅速，但在不同的空间和时间分辨率下，由于地貌

的复杂性、影像中物体和光谱地变化以及准确的数据配准等原因，利用多源遥感数据进行船舶融合分类仍然具有很强的挑战性。

1.2 国内外研究现状

1.2.1 基于深度学习的陆地建筑物损毁分类研究

传统的地震建筑物损毁分类方法主要包括纹理特征分析^[3]和面向对象分类^[4]。纹理特征分析方法主要通过提取建筑物在灾前和灾后遥感影像中的纹理特征，并构建特征向量进行损毁分类。面向对象分类方法主要通过将遥感影像中的像元根据空间位置、颜色和纹理等特征聚合成一个个对象，利用对象的空间和属性信息进行建筑物损毁分类。但受限于建筑物纹理复杂度和材质，并且需要人为的设计特征，这些方法存在图像分割不理想、特征选择困难等问题。并且在复杂的灾害场景中模型的分类精度和泛化性能较低^[5]。

随着深度学习的发展，卷积神经网络（CNN）作为其重要分支，具有强大的特征学习和推理能力，在图像处理任务上展现出了强大的性能和潜力，已经在图像分类领域取得了显著的成果^[6]。与传统的分类方法相比，基于 CNN 的分类方法能够自动选择和提取特征，具有较强的自学习能力和鲁棒性。因此，CNN 被广泛用于建筑物的损毁评估研究。根据使用的影像数量，建筑物损毁评估方法可以划分为双时相方法和单一时相方法^[7]。

双时相方法分别从灾前和灾后影像中提取特征，然后确定建筑物的位置和损毁程度^[7]。Wu 等人构建了一种包含不同 backbone 的孪生神经网络自动地检测影像中的损毁建筑，并利用注意力门结构过滤无用的特征^[8]。Xiao 等人提出了一种动态交叉融合网络，使建筑物的定位和损毁分类任务能够共享 CNN 网络不同层次的特征信息，加强了跨任务的信息交换^[9]。Adriano 等人提出了一种结合多模态和多时相数据的建筑物损毁评估网络，增加模型在不同数据源下的实用性^[10]。由于双时相方法采用了灾前和灾后的影像，通常具有较高的评估精度^[11]。然而由于受到双时相影像收集的影响，双时相评估方法的实用性相对较低^[12]。

单一时相方法仅使用灾后的影像进行建筑物的损毁评估。因此，该方法受到的制约相对较少。Duarte 等人提出了一种结合多分辨率特征融合的 CNN，提升模型在多分辨率影像中的评估性能^[13]。Ji 等人探究了利用预训练的 CNN 和微调 CNN 策略对地震中的建筑物进行损毁分类^[14]。Francesco Nex 等人评估了 CNN 模型在不同地点和不同空间分辨率影像中的迁移性能^[15]。Ishraq 等人将 CNN 中的全

连接层使用全局平均池化层替代, 评估建筑物在飓风中的损毁情况^[16]。然而, 现有的大多数研究将建筑物划分为完好和倒塌两类, 不能满足救援和灾后损失精细化评估的需求, 需要关于建筑物损毁程度更详细的分类信息^[17]。Ci 等人将 CNN 与序数回归相结合, 利用建筑物不同损毁程度之间的序数关系, 把建筑物损毁划分为四个类别: 完好、轻微损毁、严重损毁和倒塌^[18]。Ma 等人利用 GIS 数据可以提供建筑物清晰边界的特性, 提出了一种结合 GIS 数据的 CNN 模型。该模型将建筑物损毁划分为轻微损坏、中度损毁和严重损毁三个类别^[2]。然而, 这些研究忽略了建筑物损毁特征的提取对评估精度的影响。在灾后影像中, 建筑物的形状和纹理特征发生了显著变化^[19]。区分轻微损毁和严重损毁的建筑物是一项具有挑战性的任务, 因为它们具有相似的特征。例如, 建筑物的损毁特征主要表现在屋顶, 只是损坏的区域的面积不同。因此, 有必要聚集像似的损毁特征, 以加强对不同程度损坏程度建筑物的区分^[20]。此外, 建筑物周围的纹理和空间信息也可以为评估提供必要的辅助信息。探索影像中全局特征和局部特征之间的关系有助于模型更加精确的对建筑物的损毁等级进行分类。

1.2.2 基于深度学习的海面船舶目标分类研究

卫星遥感影像具有覆盖范围广、信息丰富的特点, 广泛用于海面船舶目标的监测。根据监测任务要求的不同, 将船舶监测任务分为 L1、L2 和 L3 三个等级^[21]。L1 级的任务是船舶目标的探测, 判断影像中是否存在船舶; L2 级的任务是多个大类船舶类别的识别, 判断船舶是否属于其中某一个类别; L3 级的任务是细分类船舶类型的识别, 判断船舶属于某个类别下的不同型号。

近年来, 基于深度学习的船舶监测成为了研究热点, SSD^[22]、YOLOv3^[23]、YOLOv4^[24]、R-CNN^[25]、Faster R-CNN^[26]等模型应用于船舶监测任务中。许多研究者在 L1 级的船舶监测研究中已经取得了很好的成果。江等人减少 YOLOv4 中主干网络和 PANet 中的卷积层数, 使用非次采样拉普拉斯金字塔分解提取影像中船舶的轮廓信息和去除噪声, 提升检测速度的同时保证了精度^[27]。付等人针对影像中船舶目标分布密集相互遮挡的问题, 在 YOLOv4 的特征融合网络末端添加了通道和空间注意力机制抑制无关信息, 提升船舶检测的精度^[28]。张等人设计了包含可分离卷积、多感受野等模块的 HyperLi-Net 网络用于海面船舶的检测, 提升了检测速度和精度^[29]。康等人在 R-CNN 中通过融合深层语义和浅层高分辨率特征, 提高了网络对小型船舶的检测能力^[30]。赵等人对 Faster R-CNN 中 ROI 池化层提取后的特征使用通道注意力机制抑制冗余特征信息, 提升网络对船舶的探测能力^[31]。

由于 L1 级的海面船舶监测只能判断影像中是否存在船舶，不能对船舶进行分类，一些研究人员开始更加关注 L2 级的船舶监测。

在 L2 级的船舶监测任务中主要使用 SAR 影像和光学影像。由于 SAR 影像可以不受天气的影响，一些船舶监测的研究优先考虑使用 SAR 影像。Bentes 等人提出了一种基于多分辨率影像的 CNN 模型，该模型通过输入不同分辨率的影像提高了 CNN 模型的特征提取能力^[32]。张等人提出了一种 HOG-ShipCLSNet 网络。该网络通过融合不同深度、不同尺度的特征和全局注意力机制提升网络的特征表示能力，以此来提高船舶的分类精度^[33]。马等人开发了一种多分辨率输入的单镜头多盒检测器，可以在不同分辨率的影像中提取更多的特征，实现对船舶的检测和分类^[34]。与 SAR 影像相比，光学影像可以提供丰富的细节信息。因此，一些研究者更加关注使用光学遥感影像进行船舶监测。陈等人在 YOLOv3 中引入扩张注意力机制模块，使用通道和空间注意力机制来提取显著特征，突出影像中船只和背景的差异^[35]。然而，他们只是将船只按照大小进行分类，不能判断船舶的具体类别。封等人使用空间变换裁剪操作裁剪出影像中的船舶目标，消除背景等噪声，更好地提取不同类型船舶之间的边缘视觉差异信息^[36]。张等人使用 Faster R-CNN 与 Mask R-CNN 对船舶进行分类^[37]。然而，这些研究中使用的都是单一数据源。光学影像容易受到云、雾的污染，而 SAR 影像通常含有大量的散斑噪声，这将影响船舶分类的准确性。单一数据源并不能满足复杂海况下船舶分类的要求。通过将光学影像丰富的空间和光谱信息与 SAR 影像不受天气条件干扰的优点相结合，是一个提高船舶分类精度的良好策略。

多源遥感数据融合技术根据不同的处理特点和抽象程度不同，主要分为像素级融合、特征级融合以及决策级融合^[38]。

像素级融合是指直接在原始数据层上进行融合，经常用于相同底层物理机制控制的同质传感器^[39]。在特征级融合层次中，将从多个传感器影像中提取的数据转换为相同的特征空间，然后这些特征被合并成一个综合的特征空间，该方案提高了特征表达的多样性和信息含量。但是由于对影像信息进行了压缩，会丢失很多细节性的特征^[40]。在决策级融合层次中，不同传感器采集的数据被用于训练不同的分类器或模型，然后将这些分类器或模型的输出结果根据实际的需求和一定的准则合并成一个最终的最优分类结果。决策级融合由于层次和抽象等级最高，因此，能够实现最高程度的实时融合，并且计算量最小。与像素级和特征级融合方法相比，决策级融合方法保持了不同信源下分类器选择的独立性和多样性，减

少了结果对特定传感器的依赖^[41]。并且决策级融合可以对不同平台传感器采集的数据选择合适的模型进行处理和分析,能够满足不同场景的融合需求^[42]。

决策级融合包括两个关键的过程。首先是获取经过时空配准的多源遥感影像。尽管现在已有一些公开的船舶分类数据集^[21, 43-47],但是它们都是单源数据集。获取可用于船舶分类的多源遥感数据是一项有难度的工作。因为不同的卫星有不同的分辨率和重访周期,以及船舶目标比较小也加大了影像获取的难度。更重要的是,船舶是一种运动的物体。在计算机视觉图像翻译研究中,生成式对抗网络(GANs)在图像到图像的转换中具有出色的性能。许多基于GAN的方法在SAR影像与光学影像的相互转换任务中取得了巨大的成功,如Pix2Pix^[48]、CycleGAN^[49]等。Schmitt等人利用Pix2Pix网络将SAR影像转换为光学影像,探究了从SAR影像到人工光学影像的预测^[50]。王等人提出一种监督循环一致性对抗网络(S-CycleGAN)用于从SAR影像生成光学影像以帮助人们进行土地覆盖类型的识别^[51]。傅等人建立了基于级联的残差对抗生成网络CRAN进行SAR与光学影像的相互转换用于帮助人们对SAR影像进行辅助判读^[52]。其次,需要对不同数据源中船舶目标的分类结果进行融合判定,提高船舶的分类精度。

现有的决策级融合方法主要包括:多数投票^[53]、加权多数投票^[53]、基于决策模板^[54]和基于排序的决策融合^[55]等。马等人在遥感影像的小目标检测任务中,使用不同的权重组合对子网络的检测结果进行决策级融合,得出最优权重组合^[56]。毕等人在近岸船舶的检测中,在候选区域识别阶段设计了三个子模型对船舶候选区域进行提取,并使用决策模板对三个子模型的提取结果做决策融合^[57]。黄等人在船舶分类中,设计了三种特征提取算法,将提取的特征经过SVM进行分类,并对分类器的分类结果使用决策级融合算法进行融合,每个分类器所占权重相等^[58]。R.Huan等人在微小目标分类时,采用基于排序的决策级融合算法对不同分类器的分类结果进行融合判定^[59]。唐等人将光学影像与红外影像中的识别结果进行叠加,然后去除重叠率高的目标框,同时保留高置信度的目标检测框作为最终的检测结果^[60]。然而,这些研究中不同分类器在融合过程中分类器识别结果所占权重需要人为设置或依赖测试集的先验结果,影响了模型的鲁棒性。

根据上述研究,船舶分类中还存在一些问题。首先,由于船只是一种运动的物体,获取时空配准的异源影像是一个巨大的挑战。其次,现有的大多数研究主要关注模型的特征提取性能,很少有研究关注预测框定位的准确性对船舶分类精度的影响。最后,决策级融合算法中不同分类器的权重大部分是通过手动设置或

依赖于先验知识确定，会导致模型的鲁棒性较差。因此，有必要提出一种自适应的方法来提高决策级融合分类的准确性。

1.3 主要研究内容

本文全面研究了基于深度学习的海陆目标分类，主要针对建筑物地震损毁等级分类以及海面船舶目标分类开展研究。

针对建筑物损毁多级分类问题，本文提出了一种基于 CNN 的建筑物地震损毁分类网络 EBDC-Net，使用灾后航空影像评估建筑物的损毁程度。所提出的网络包含一个建筑物损毁特征提取编码器模块和一个建筑物损毁分类模块。特征提取编码器模块用于从影像中提取语义信息并增强对不同损毁等级建筑物的特征表示能力。而建筑物损毁分类模块则用于融合全局和上下文特征以提高建筑物损毁分类的准确性。

针对仅使用单源影像进行船舶目标分类时模型抗干扰能力低的问题，本文提出一种利用多源遥感影像进行 L2 级船舶分类的模型，该模型包含多源影像生成、单源影像船舶分类和多源影像决策级融合分类三个模块。首先，多源影像生成模块基于 CycleGAN 网络建立了 OPT-SAR 影像转换模型将光学影像转换为 SAR 影像，建立了一个包含多源遥感影像的船舶分类数据集。其次单源影像分类模块将高斯模型引入到 YOLOv4 目标分类模型中，提高了 SAR 和光学影像中船舶目标分类的精度。决策级融合分类模块中建立了自适应加权的决策级融合模型对单源数据下的分类结果进行融合判定，提升模型在不同海况下对船舶目标类别判定的鲁棒性。

基于深度学习的海陆目标分类模型的总体框架如图 1-1 所示，主要分为数据处理、模型构建与训练以及模型评估三个部分：

数据处理，主要是对获取的遥感影像进行预处理。建筑物地震损毁分类数据集中主要包含航空影像和无人机（UAV）影像，从大幅面影像中裁剪出感兴趣的区域并按照建筑物地震损毁分类标准对影像中的建筑物损毁等级进行分类。船舶分类数据集中主要包含光学影像和 SAR 影像，并对影像中不同的类别船舶进行标注。

模型构建与训练，主要构建了建筑物损毁分类模型、OPT-SAR 影像生成模型、光学船舶分类模型、SAR 船舶分类模型以及决策级融合分类模型。将光学影像输入到 OPT-SAR 影像生成模型中生成伪 SAR 影像，以获得匹配的光学-SAR 匹配的影像对。分别输入到光学和 SAR 船舶分类模型中，最后通过决策融合分类模型对

分类结果进行决策级融合判定。利用建筑物地震损毁分类数据集训练建筑物损毁分类模型，利用多源船舶分类数据集训练船舶分类模型。

模型评估，主要包括建筑物损毁分类精度评估、建筑物损毁效率评估、船舶分类精度评估和对 OPT-SAR 影像生成模型生成的仿真影像的质量进行评估。用以验证模型的有效性和鲁棒性。




图 1-1 基于深度学习的海陆目标分类方法总体框架图

Fig.1-1 The overall framework of the classification method of sea and land targets based on deep learning

本文主要分为 4 章，每章的主要内容组织如下：

第一章为引言部分，首先简要的介绍了建筑物地震损毁分类和海面船舶目标分类的研究目的和意义。然后对基于深度学习的陆地建筑物损毁分类研究以及基于深度学习的海面船舶目标分类研究的国内外现状进行了讨论。最后介绍了本文的主要研究内容，同时对后续章节的安排进行说明。

第二章主要介绍了基于深度学习的建筑物损毁分类方法。首先介绍了本文提出的 EBDC-Net 建筑物损毁分类网络。然后介绍了实验所使用的数据、模型参数

选取设定的方法、实验的相关设置以及相应的实验结果。最后讨论了历史地震数据在新发生地震中的作用，同时评估了模型在使用大幅面无人机影像进行建筑物损毁评估时的效率和精度以及得出了一些结论。

第三章主要介绍了基于深度学习的多源船舶目标决策级融合分类方法。首先介绍了本文提出的基于 CycleGAN 的 OPT-SAR 多源影像生成模型，通过该模型的建立，能够获取匹配的多源遥感影像，建立多源遥感影像船舶分类数据集。然后介绍了本文提出的基于 YOLOv4 的单源船舶目标分类算法以及提出的自适应加权的多源数据决策级融合分类算法。其次描述了实验的相关设置、用于精度评估的参数以及对船舶分类结果的分析。最后讨论了所提出的方法在不同海况下的性能以及得出了一些结论。

第四章是本文的总结部分，对本文所做的主要工作进行了总结，并探讨了研究中存在的不足和后续相关研究的展望。

第 2 章 基于 EBDC-Net 网络的建筑物地震损毁分类

2.1 EBDC-Net 建筑物地震损毁分类网络

为了提高建筑物地震损毁分类的精度，本研究提出了一种名为 EBDC-Net 的建筑物损毁分类网络，如图 2-1 所示。EBDC-Net 由建筑损毁特征提取编码器模块和建筑物损毁分类模块构成。首先，构建了一个特征提取编码器模块用于提取不同损毁等级建筑物的语义信息。在特征提取时利用空间注意力机制（SAM）模块聚集影像中的相似特征，增强网络的特征表示能力。并利用残差结构增加网络对特征留存的能力。其次，在建筑物损毁分类模块中构建了全局特征提取（GFE）和上下文特征提取（CFE）两个并行的模块，充分挖掘影像中的全局特征信息和上下文特征信息以提高建筑物损毁分类的精度。最后建立了两个全连接层对建筑物的损毁等级进行分类。




图 2-1 EBDC-Net 建筑物损毁分类网络

Fig.2-1 EBDC-Net building damage classification network

2.1.1 特征提取编码器模块

从灾后航空影像中提取有效的特征有助于确定建筑物的受损程度^[61]。如图 2-1 所示，灾后航空影像作为 EBDC-Net 的输入数据。EBDC-Net 的编码器网络由 4 个卷积块堆叠而成。在块 1 和块 2 中，每个卷积块包含 2 个 2D 卷积（kernel=3）。在块 3 和块 4 中，每个卷积块包含 3 个 2D 卷积（kernel=3）。在每个卷积操作后都有一个最大池化的下采样操作（kernel=2）。此外，由于本研究中输入的影像的尺寸较小，随着网络的加深，特征丢失严重。残差连接结构可以让网络在深度增加的同时特征保留的能力也更强。它能减缓网络的退化，降低优化难度，并且

有助于设计更优的网络模型^[62]。因此，为了进一步提高网络的性能，在后三个卷积块中加入了残差连接结构来增加网络的深度，增强网络对特征的留存能力，从而提取更深层的特征。

尽管卷积块能够提取不同层次的语义信息，然而，在灾后的遥感影像中，轻微损毁和严重损毁的建筑物其损毁特征分散地分布在影像的不同区域且损毁特征在影像中占有的比例较小，导致影像中不同损毁类别之间的类内方差较大。为了增强网络的特征表示能力，获得更好的分类精度，在每个卷积块的最后引入了一种空间注意力机制（SAM）^[63]。SAM 模块能够自适应地探索影像中不同位置特征之间的相似性，整合任意尺度相似的特征，增加不同损毁等级之间的类内一致性，并抑制了不必要的信息和噪声，提升网络提取特征的有效性。




图 2-2 空间注意力机制模型

Fig.2-2 Spatial attention mechanism model

如图 2-2 所示，空间注意力机制模块接收卷积块提取的特征图 $F_A \in R^{C \times H \times W}$ ，其中 C, H, W 分别代表 F_A 的通道、高和宽。首先， F_A 作为输入，经过两个卷积层（ $\text{kernel}=1$ ），得到两个新的特征图 F_B 和 F_C 。这两个卷积层的输出通道为 $C/8$ 。其次将 F_B 进行 reshape 操作，转换为 $R^{N \times (\frac{C}{8})}$ ，将 F_C 进行 reshape 操作，转换为 $R^{(\frac{C}{8}) \times N}$ ，其中 $N = H \times W$ 。随后将 F_B 和 F_C 进行矩阵相乘操作生成一个特征图 $F_S, \in R^{N \times N}$ 。最后， F_S 被送入 SoftMax 层进行处理，并生成空间注意力特征权重图 $F_S \in R^{N \times N}$ ，计算公式如式 2-1 所示。

$$F_{S_{ji}} = \frac{\exp(F_{B_i} \cdot F_{C_j})}{\sum_{i=1}^N \exp(F_{B_i} \cdot F_{C_j})} \quad (2-1)$$

空间注意力特征权重图 $F_{S_{ji}}$ 用来衡量空间中任意两个位置特征之间的影响，两个位置的特征表示越接近说明它们之间的相关性越强， $F_{S_{ji}}$ 的值越大。在获得空间注意力权重特征图 F_S 后，将特征图 F_A 输入到另一个新的卷积层中进行处理，得到一个新的特征图 F_D 。 F_D 和 F_A 具有相同的形状。在空间注意力权重特征图 F_S 与特征图 F_D 之间进行矩阵的乘法，并将结果进行 reshape 操作，转换为 $R^{C \times H \times W}$ 。最后将该结果与一个可训练的尺度系数 α 相乘并与 F_A 进行求和运算得到最终的特征图 F_E ， α 的初始值为 0，计算公式如式 2-2 所示。

$$F_{E_j} = SAM(F_A) = \alpha \sum_{i=1}^N F_{S_{ji}} F_{D_i} + F_{A_j} \quad (2-2)$$

根据公式 2-2，特征图 F_{E_j} 每个位置的值是由 F_S 中的值作为权重值对原始特征进行加权融合得到。因此，SAM 模块有选择地聚合相似的语义特征，提高了不同损毁等级之间的类内紧凑性和语义一致性，使得网络能够更好地区分不同损毁等级的建筑物，提升建筑物损毁等级分类的精度。

2.1.2 建筑物损毁分类模块

在使用灾后的航空影像进行建筑物损毁等级分类时，若仅仅关注建筑物本身的特征不足以准确地区分其损毁等级。建筑物周围的场景能够为损毁评估提供必要的辅助信息。如果根据影像中的全局信息和上下文的依赖关系可能会对最终的损毁分类结果会有所改善。

如图 2-1 所示，在 EBDC-Net 的建筑物损毁分类网络中设计了两个并行的模块分别用于捕获影像中的全局信息和上下文特征依赖关系。特征编码器模块提取的特征 F 作为建筑物损毁分类模块的输入。具体而言，首先，将 F 喂入 GFE 模块中，在 GFE 模块中使用全局平均池化层来提取影像的全局信息，得到影像的全局特征 F_G 。然后将 F 喂入 CFE 模块中。在 CFE 模块中，长短期记忆网络（LSTM）层^[64]被用来提取影像中的上下文特征依赖关系，得到影像的上下文特征 F_C 。

LSTM 作为一种深度回归神经网络，能够处理记忆序列信息的长期关系^[64]。在许多遥感影像分类研究中利用 LSTM 提取影像中的空间和光谱特征^[65-67]。在本研究中，LSTM 被用来探索不同区域特征序列之间的上下文依赖关系。特征序列的生成是学习上下文特征依赖关系的关键。如图 2-3 所示，将特征 $F \in R^{C \times H \times W}$ 划分为 $H \times W$ 个网格，每个网格作为一个 C 维的特征向量。通过转换得到特征序列

$V = [x_1, x_2, \dots, x_K] \in R^C$ ，其中 $K = H \times W$ 。将每个 C 维特征向量 x_k 作为特征序列依次喂入 LSTM 层提取影像中的上下文特征。




图 2-3 特征序列生成模型

Fig.2-3 Feature sequence generation model




图 2-4 LSTM 处理单元

Fig.2-4 LSTM processing cell

如图 2-4 所示，LSTM 有三个输入：当前特征序列的输入值 x_k 、上一特征序列的输出值 h_{k-1} 和它的单元状态 C_{k-1} 。LSTM 有两个输出：当前序列特征的输出值 h_k 和它的单元状态 C_k 。遗忘门 f_k 结合 h_{k-1} 和 x_k 决定上一特征序列的单元状态 C_{k-1} 有多少保留到当前特征序列中。输入门 i_k 结合 h_{k-1} 和 x_k 决定当前特征序列的输入 $\tilde{C}_k$ 有多少保存到新的单元状态 C_k 中。输出门 o_k 结合当前特征序列的单元状态 C_k 对当前输出值 h_k 进行控制。基于这些部分，不同特征序列之间的依赖关系可以通过式 2-3 至式 2-8 进行计算：

$$f_k = \sigma(W_f \cdot [h_{k-1}, x_k] + b_f) \quad (2-3)$$

$$i_k = \sigma(W_i \cdot [h_{k-1}, x_k] + b_i) \quad (2-4)$$

$$\tilde{C}_k = \tanh(W_C \cdot [h_{k-1}, x_k] + b_C) \quad (2-5)$$

$$C_k = f_k \circ C_{k-1} + i_k \circ \tilde{C}_k \quad (2-6)$$

$$o_k = \sigma(W_o \cdot [h_{k-1}, x_k] + b_o) \quad (2-7)$$

$$h_k = o_k \circ \tanh(C_k) \quad (2-8)$$

其中, σ 代表 sigmoid 函数, $\circ$ 代表点积运算, W_f, W_i, W_C, W_o 和 b_f, b_i, b_C, b_o 是可学习的权重。最后一个特征序列的输出状态作为上下文特征 F_C 来描述影像中的上下文特征依赖关系。在 CFE 模块中, 串联了两个 LSTM 层, 每个 LSTM 层的输出维度为 256。

在得到全局特征 F_G 和上下文特征 F_C 后, 将两种特征喂入 Concatenate 层进行有效连接得到融合特征 F_{fusion} , 计算方式如式 2-9 所示。然后将 F_{fusion} 喂入两个维度为 256 的全连接层中。值得注意的是, 为了避免过拟合, 采用了 dropout 策略。最后, 经过 SoftMax 层处理获得建筑物最终的损毁类别。


$$F_{fusion} = [F_G, F_C] \quad (2-9)$$

2.2 建筑物地震损毁分类数据集

本研究中使用的数据集包含三个不同地点的震后影像。第一个是 2010 年 4 月 14 日发生在中国青海省玉树县的 7.1 级地震的震后航空影像。第二个是 2014 年 8 月 3 日发生在中国云南省鲁甸县的 6.5 级地震的震后航空影像。第三个是 2021 年 5 月 21 日发生在中国云南省漾濞县的 6.4 级地震的震后无人机影像。

表 2-1 数据集中四个损毁等级的建筑物示例和影像信息

Tab.2-1 Building examples and image information of the four damage levels in the datasets

数据集	基本完好	轻微损毁	严重损毁	倒塌	图像大小	分辨率
玉树数据集					88×88 像素	0.1m
鲁甸数据集					88×88 像素	0.2m
漾濞数据集				—	88×88 像素	0.03m-0.2m

玉树和鲁甸震后航空影像作为公开数据集，能够从https://github.com/city292/build_assessment 获取^[18]。玉树数据集和鲁甸数据集参考 EMS-98^[68]建筑物损毁分类标准对数据集中的建筑物进行损毁分类。其中，损毁类别 L0 对应 EMS-98 中的 G0-2，L1、L2 和 L3 分别对应 EMS-98 中的 G3、G4 和 G5。对于漾濞数据集，本文参照玉树和鲁甸数据集的格式进行相应的处理。首先从漾濞地震的灾后无人机影像中裁剪出包含建筑物的区域。然后，根据影像的分辨率和当地建筑物的结构特征确定合适的 patch 大小，将影像裁剪成不同大小的 patch。最后将所有的 patch 统一进行 resize 操作，得到 88×88 像素大小的影像块。并按照与玉树数据集和鲁甸数据集中相同的分类标准对影像中的建筑物进行损毁分类。如表 2-1 所示，该数据集将建筑物损毁划分为四个不同的损毁类别：基本完好、轻微损毁、严重损毁和倒塌。如表 2-2 所示，对数据集中不同损毁等级的影像数量进行了统计。

表 2-2 不同损毁等级建筑物样本数量统计

Tab.2-2 Statistics on the number of buildings sampled with different damage levels

损毁类别	描述	鲁甸数据集	玉树数据集	漾濞数据集
L0	基本完好	1630	778	928
L1	轻微损毁	3074	918	202
L2	严重损毁	1685	665	111
L3	倒塌	1984	1140	—
总计		8337	3510	1241

表 2-3 三种不同划分标准的建筑物损毁等级分布

Tab.2-3 Distribution of building damage levels for the three classification criteria

Group	描述	损毁类别
1	未到塌	L0, L1, L2
	倒塌	L3
2	基本完好	L0, L1
	严重损毁	L2
	倒塌	L3
3	基本完好	L0
	轻微损毁	L1
	严重损毁	L2
	倒塌	L3

为了验证 EBDC-Net 在不同分类标准上的性能，如表 2-3 所示，将不同损毁程度的建筑物影像分为三组。Group1 简单地将所有建筑物划分为基本完好和倒塌两个类别。将 L0、L1、L2 进行合并，包含未到塌和倒塌两个类别。Group2 将 L0 和 L1 进行合并，包含基本完好、严重损毁和倒塌三个类别。Group3 设计了更详细的分类标准，将所有建筑划分为四个类别，分别为基本完好、轻微损毁、严重损毁和倒塌。

2.3 实验结果与分析

2.3.1 实验设置

本研究中所有的实验和测试都在配置为 32GB 内存，i7 • 9800X @3.8GHz CPU 和 GeForce RTX 2080Ti • GPU 的同一平台上进行。鲁甸数据集被随机划分为训练集、验证集和测试集，划分比例为 8:1:1。考虑到玉树数据集和漾濞数据集的影像数量，它们的划分比例为 6:2:2。在本研究中，采用总体精度（OA）、Kappa 系数和均方误差（MSE）评估模型的分类精度。OA、Kappa 系数用于评估分类器的分类结果与真实类别的一致性，MSE 用于衡量回归模型的误差率。OA 的计算方式如式 2-10 所示，Kappa 的计算方式如式 2-11 和式 2-12 所示，MSE 的计算方式如式 2-13 所示。

$$OA = \frac{\sum_i^K C(i, i)}{\sum_i^K \sum_j^K C(i, j)} \quad (2-10)$$

$$p_e = \frac{\sum_i^K (\sum_j^K C(i, j) * \sum_j^K C(j, i))}{N^2} \quad (2-11)$$

$$kappa = \frac{OA - p_e}{1 - p_e} \quad (2-12)$$

其中，N 表示样本总数。

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2-13)$$

其中， y_i 表示建筑物真实的损毁类别， $\hat{y}_i$ 表示模型预测的建筑物损毁类别，N 表示样本总数。

为了获得最佳的超参数，首先测试了不同 Batch Size 和学习率对建筑物损毁分类精度的影响。在测试时，固定其中一个超参数，调整另一个参数，观察模型精度的变化。本研究中，在鲁甸数据集中测试了 EBDC-Net 网络在不同学习率和

Batch Size 大小组合下的分类精度。如表 2-4 所示, 当学习率为 0.0001 时, 模型的分类精度随着 Batch Size 的增加而增加。当 Batch Size 为 32 时, 模型的精度达到最高。继续增大 Batch Size 后模型的精度出现了下降, 这是由于在影像数量较小时, 过大的 Batch Size 会使得模型在每个 epoch 期间迭代的次数下降, 使得模型学习在局部达到了最优解, 从而导致模型的泛化性能下降。在筛选最优学习率时也得出了类似的结论, 如表 2-5 所示, 当学习率为 0.0001, 批量大小为 32 时, 模型的分类精度最高。同时, 如图 2-5 所示, 通过绘制模型的损失值随着 epoch 的变换关系图能够得出, 当模型训练 100 个 epoch 时, 模型已经达到了收敛。

表 2-4 不同 batch size 模型的分类精度

Tab.2-4 Classification accuracy of model with different batch size

测试	OA (%)	Kappa	MSE
LR-0001-BS-8	68.39	0.56	0.44
LR-0001-BS-16	75.00	0.65	0.28
LR-0001-BS-32	77.49	0.69	0.26
LR-0001-BS-64	75.96	0.67	0.28

表 2-5 不同学习率模型的分类精度

Tab.2-5 Classification accuracy of model with different learning rates

测试	OA (%)	Kappa	MSE
LR-001-BS-32	29.02	0.06	0.93
LR-0001-BS-32	77.49	0.69	0.26
LR-00001-BS-32	68.58	0.57	0.40




图 2-5 损失值曲线

Fig.2-5 Loss value curve

基于上述的实验,在本研究中,所有模型的训练采用了 SGD 优化器,交叉熵损失函数。初始学习率为 0.0001,权重衰减率为 0.001。为了提高训练效率和减少内存消耗,设置 Batch Size 为 32,并将训练 epoch 设为 100,以确保模型获得足够的训练次数并逐步收敛。为了更公平地比较提出的 EBDC-Net 与其他方法的精度,训练时的超参数设置与比较的方法相同。另外,使用在 ImageNet 上的预训练权重初始化特征提取编码器网络,训练时使用水平翻转和垂直翻转进行数据增强。

2.3.2 不同基线模型建筑物损毁分类精度比较

本研究首先比较了鲁甸和玉树数据集中不同基线模型的性能。由于漾濞数据集中不存在倒塌的建筑物,导致无法根据上述分组标准将漾濞数据集分为三组。因此,漾濞数据集被用于讨论模型的迁移性能。通过将 EBDC-Net 中的残差连接、空间注意力机制模块、上下文特征提取模块去除构建了本研究中的基线模型 EBDC-Baseline。在 Group1、Group2 和 Group3 三种不同建筑损毁分类标准中比较了七种基线模型的性能,包括 DenseNet^[69]、ResNet50^[62]、InceptionV3^[70]、Xception^[71]、MobileNet^[72]、VGG16^[73]和 EBDC-Baseline。

表 2-6 不同基线模型在鲁甸数据集中的建筑物损毁分类精度

Tab.2-6 Building damage classification accuracy of different baseline models in Ludian dataset

模型名称	Group1			Group2			Group3		
	OA(%)	Kappa	MSE	OA(%)	Kappa	MSE	OA(%)	Kappa	MSE
DenseNet	91.09	0.76	0.09	79.21	0.65	0.27	69.63	0.58	0.43
ResNet50	92.52	0.79	0.07	81.32	0.68	0.20	71.26	0.61	0.37
InceptionV3	92.62	0.79	0.07	81.41	0.68	0.23	72.99	0.63	0.35
Xception	92.43	0.79	0.08	79.12	0.64	0.26	65.80	0.53	0.43
MobileNet	92.81	0.80	0.07	80.46	0.66	0.24	72.22	0.62	0.33
VGG16	93.29	0.81	0.06	81.61	0.68	0.22	73.37	0.63	0.30
EBDC-Baseline	93.39	0.82	0.06	83.52	0.72	0.18	74.23	0.64	0.30

表 2-6 和表 2-7 分别展示了不同基线模型在鲁甸数据集和玉树数据集中建筑物损毁分类精度的定量比较结果。从表 2-6 中可以看出,由于分类标准相对简单,所有七个基线模型在 Group1 中表现出了相似的性能,总体准确度均高于 90%。然而,随着建筑物损毁类别划分数量的增加,不同模型之间的性能差异变大,尤其是在 Group3 中,模型的分类精度大幅下降。在所有的基线模型中,本研究中所构

建的 EBDC-Baseline 在鲁甸数据集的三种分类标准中的 OA、Kappa 和 MSE 均表现出最好的性能。

在玉树数据集中也得出了类似的结论。如表 2-7 所示，对于 Group1，所有基线模型都表现出优异的性能，总体精度均高于 90%。在所有基线模型中，VGG16 在 Group1 中表现出最佳的 OA，比本研究采用的基线模型高 0.42%。对于 Group2 和 Group3，本研究中所采用的基线模型获得了最佳 OA，比 VGG16 分别高 0.85%和 1.28%。

表 2-7 不同基线模型在玉树数据集中的建筑物损毁分类精度

Tab.2-7 Building damage classification accuracy of different baseline models in Yushu dataset

模型名称	Group1			Group2			Group3		
	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE
DenseNet	92.44	0.82	0.07	76.32	0.60	0.38	63.34	0.50	0.66
ResNet50	93.58	0.85	0.06	76.03	0.61	0.32	63.20	0.50	0.60
InceptionV3	92.58	0.83	0.07	75.46	0.58	0.35	63.62	0.51	0.58
Xception	92.86	0.84	0.07	76.46	0.61	0.29	61.91	0.48	0.59
MobileNet	92.87	0.84	0.07	75.19	0.58	0.39	64.05	0.51	0.59
VGG16	93.72	0.86	0.06	76.18	0.63	0.27	63.91	0.51	0.52
EBDC-Baseline	93.30	0.85	0.07	77.03	0.64	0.26	65.19	0.53	0.47

2.3.3 消融实验结果

本研究在鲁甸数据集和玉树数据集上进行了消融实验，展示了 EBDC-Net 中不同模块对建筑物损毁分类的贡献。其中 R 代表残差连接模块，S 代表空间注意力机制模块，C 代表上下文特征提取模块。表 2-8 和表 2-9 分别展示了两个数据集中不同模块的消融实验结果比较。与 EBDC-Baseline 相比，当模型中同时加入残差连接模块、空间注意力机制模块和上下文特征提取模块时，在三种不同分类标准的任务中表现出的总体精度最高。与 EBDC-Baseline 模型相比，在鲁甸和玉树数据集中，EBDC-Net 在 Group1 上分别提升了 1.05%和 1.42%，在 Group2 上分别提升了 2.01%和 1.99%，在 Group3 上分别提升了 3.26%和 2.43%。

从表 2-8 和表 2-9 可以看出 EBDC-Net 在类别划分越细的建筑物损毁分类任务中对精度的提升越明显。首先得益于残差连接在网络加深时缓解了损毁特征的丢失现象。其次，SAM 模块能够聚集影像中分散的损毁特征，增强网络对损毁特征的表示能力，提升网络对中间损毁等级建筑物的区分能力。最后，分类网络综合

利用影像中的全局特征和上下文特征，充分利用建筑物周围的环境信息，提高了建筑物损毁分类的精度。

表 2-8 鲁甸数据集中 EBDC-Net 不同模块对建筑物损毁分类精度的影响

Tab.2-8 The effects of different modules in EBDC-Net on the accuracy of building damage classification in the Ludian dataset


模型名称	Group1			Group2			Group3		
	OA(%)	Kappa	MSE	OA(%)	Kappa	MSE	OA(%)	Kappa	MSE
EBDC-Baseline	93.39	0.82	0.07	83.52	0.72	0.18	74.23	0.64	0.30
EBDC-Baseline +R	93.58	0.82	0.06	83.81	0.72	0.18	75.19	0.66	0.27
EBDC-Baseline +R+S	93.67	0.82	0.06	84.10	0.72	0.17	76.14	0.67	0.27
EBDC-Baseline +R+S+C	94.44	0.83	0.06	85.53	0.75	0.17	77.49	0.69	0.26

表 2-9 玉树数据集中 EBDC-Net 不同模块对建筑物损毁分类精度的影响

Tab.2-9 The effects of different modules in EBDC-Net on the accuracy of building damage classification in the Yushu dataset

模型名称	Group1			Group2			Group3		
	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE
EBDC-Baseline	93.30	0.85	0.07	77.03	0.64	0.26	65.19	0.53	0.47
EBDC-Baseline +R	93.58	0.86	0.06	78.60	0.64	0.27	65.48	0.53	0.47
EBDC-Baseline +R+S	93.86	0.86	0.06	78.74	0.65	0.24	66.48	0.66	0.45
EBDC-Baseline +R+S+C	94.72	0.88	0.05	79.02	0.65	0.26	67.62	0.56	0.42

如图 2-6 所示，展示了在鲁甸和玉树数据集中 EBDC-Baseline 和 EBDC-Net 评估结果的混淆矩阵。通过比较 EBDC-Baseline 与 EBDC-Net 在鲁甸和玉树数据集上的混淆矩阵能够得出，模型对于轻微损毁和严重损毁两个类别的分类精度的提升要好于基本完好和倒塌两个类别。EBDC-Net 能够更好的区分不同损毁等级的建筑物。因此，EBDC-Net 有助于建筑物损毁的精细化评估任务。



(a) 鲁甸数据集中 EBDC-Baseline 的混淆矩阵 (b) 鲁甸数据集中 EBDC-Net 的混淆矩阵

(c) 玉树数据集中 EBDC-Baseline 的混淆矩阵 (d) 玉树数据集中 EBDC-Net 的混淆矩阵

图 2-6 EBDC-Baseline 和 EBDC-Net 在 Group3 中评估结果的混淆矩阵

Fig.2-6 Confusion matrix of EBDC-Baseline and EBDC-Net evaluation results on Group3

2.3.4 不同建筑物损毁分类方法分类精度比较

为了验证提出的 EBDC-Net 在建筑物损毁分类中的有效性, 本研究将 EBDC-Net 与其他 4 种最先进的建筑物损毁分类方法在鲁甸数据集和玉树数据集中进行了比较, 包括 Res-CNN、Dense-CNN、VGG-GAP 和 VGG-OR。Res-CNN 是利用 CBR 模块和残差连接构建的 CNN 模型^[13]。Dense-CNN 是一个利用 Dense Block 构建的 CNN 模型^[15]。VGG-GAP 是将 VGG16 中的全连接层替换为全局平均池化层所构建的模型^[74]。VGG-OR 是将 VGG16 与序数回归相结合所构建的模型^[18]。如表 2-10 和表 2-11 所示, 在两个数据集中, 本研究中所提出的 EBDC-Net 在 3 种不同的分类标准中都展现出了最好的性能。在 Group1 上的 OA 分别为 94.44%和 94.72%, 在 Group2 上的 OA 分别为 85.33%和 79.02%, 在 Group3 上的 OA 分别为 77.49%和 67.62%。与其他四种方法相比, EBDC-Net 在 Group3 上的优势比 Group1 和 Group2 上更加明显, 比 Res-CNN 的总体精度分别高 13.5%和 9.42%, 比 Dense-CNN 的总体精度分别高 8.34%和 8.13%, 比 VGG-GAP 的总体精度分别高 4.22%和 3.9%, 比 VGG-OR 的总体精度分别高 1.92%和 2.57%。

表 2-10 不同建筑物损毁分类方法在鲁甸数据集中的分类精度

Tab.2-10 Classification accuracy of different building damage classification methods in the Ludian dataset

模型名称	Group1			Group2			Group3		
	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE
Res-CNN	89.27	0.68	0.10	75.86	0.54	0.37	63.99	0.50	0.49
Dense-CNN	89.08	0.71	0.11	77.68	0.61	0.31	69.15	0.57	0.38
VGG-GAP	93.30	0.81	0.06	83.14	0.71	0.19	73.27	0.64	0.32
VGG-OR	93.29	0.81	0.06	84.58	0.74	0.17	75.57	0.66	0.26
EBDC-Net	94.44	0.83	0.06	85.53	0.75	0.17	77.49	0.69	0.26

表 2-11 不同建筑物损毁分类方法在玉树数据集中的分类精度



Tab.2-11 Classification accuracy of different building damage classification methods in the Yushu dataset

模型名称	Group1			Group2			Group3		
	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE	OA (%)	Kappa	MSE
Res-CNN	91.44	0.91	0.09	75.32	0.58	0.37	58.20	0.43	0.64
Dense-CNN	92.15	0.83	0.08	76.03	0.60	0.32	59.49	0.44	0.74
VGG-GAP	94.00	0.87	0.06	78.89	0.67	0.23	63.77	0.51	0.56
VGG-OR	93.30	0.85	0.07	77.75	0.65	0.26	65.05	0.53	0.43
EBDC-Net	94.72	0.88	0.05	79.02	0.65	0.26	67.62	0.56	0.42

如表 2-12 所示，第一张和第二影像中完好建筑物周围存在少量瓦砾，而第七张和第八张影像中的建筑物被大瓦砾所掩埋，它们的屋顶都未出现明显的损毁。因此，仅从建筑物本身的特征不能准确的区分建筑物损毁的类别。EBDC-Net 综合利用了影像中的全局特征和上下文特征，能够提升模型对建筑物周围纹理信息和空间结构的区分能力。第三到第六张影像分别对应轻微损毁和严重损毁的建筑，在这两种损毁等级的影像中，建筑物的主体保持了完整，建筑物的损毁特征分散的分布在屋顶。SAM 模块能够聚集影像中的相似特征，增强网络的特征表达能力，有助于区分中间损毁类别的建筑。

表 2-12 不同建筑物损毁分类方法的分类结果

Tab.2-12 Classification results of different building damage classification methods

模型名称								
GT	L0	L0	L1	L1	L2	L2	L3	L3
Dense-CNN	L1	L1	L2	L2	L2	L3	L3	L3
VGG-GAP	L0	L2	L2	L2	L3	L2	L2	L3
VGG-OR	L0	L1	L2	L2	L2	L2	L2	L2
EBDC-Net	L0	L0	L1	L1	L2	L2	L3	L3

(L0: 基本完好; L1: 轻微损毁; L2: 严重损毁; L3: 倒塌)

2.3.5 历史地震数据在未来地震中对建筑物损毁评估的作用

在建筑物损毁分类任务中, 模型从历史地震数据中学习建筑物的损毁特征, 在地震发生后, 使用少量新的数据微调模型有助于快速准确的对建筑物损毁等级进行评估。在本研究中, 为了探究历史地震数据在震后快速评估任务中的作用, 设计了三组测试实验。在 Test1 中, 使用鲁甸数据集训练 EBDC-Net 模型, 并在玉树数据集中进行预测。在 Test2 中, EBDC-Net 模型在玉树数据集中训练和预测。在 Test3 中, 使用玉树数据集微调在鲁甸数据集中训练好的 EBDC-Net 模型, 并在玉树数据集中进行预测。

如表 2-13 所示, 对于 Test1, 模型在 Group1 中的 OA 为 88.30%, 在 Group2 上的 OA 为 69.19%, 在 Group3 上的 OA 为 56.63%。与鲁甸数据集中的结果相比, 模型在 Group2 和 Group3 上的分类精度急剧下降。如图 2-7 所示, 两个数据集中的建筑物的结构、形状、风格都有很大的不同。模型从鲁甸数据集学习的特征不足以代表玉树数据集中受损建筑物的特征, 这导致了分类准确率降低。

同样地, 对于 Test2, 模型在 Group2 和 Group3 上的 OA 为 79.02% 和 67.62%, 低于在鲁甸数据集上的精度。这是因为玉树数据集的影像数量比鲁甸数据集少得多。这也表明, 在建筑物损毁的精细化评估中, 样本的数量对评估的准确性会有很大的影响。

然而, 对于 Test3, 在通过使用玉树数据集的额外少量影像对在鲁甸数据集上训练的模型进行微调后, 模型的准确性得到了明显的改善。从表 2-13 可以看出, 与 Test1 和 Test2 相比, 三组的总体分类精度分别为 95.86%、80.82% 和 68.33%。其中, 对 Group1 中的分类标准, 分类精度分别高了 7.56% 和 1.14%, 对于 Group2

中的分类标准，分类精度分别高了 10.83%和 1%，对于 Group3 中的分类标准，分类精度分别高了 11.7%和 0.71%。这是因为历史地震数据可以提供受损建筑物的基本特征。通过添加少量的测试区域的影像，可以学习到更多的细节和局部特征，从而提高建筑物损毁分类的准确性。这表明，微调是建筑物损毁分类的一个有效策略。

表 2-13 历史地震数据对建筑物损毁精细化评估的影响

Tab.2-13 Impact of historical earthquake data on the refined assessment of building damage

测试名称	Group1			Group2			Group3		
	OA	Kappa	MSE	OA	Kappa	MSE	OA	Kappa	MSE
Test 1	88.30	0.75	0.12	69.19	0.52	0.39	56.63	0.41	0.76
Test 2	94.72	0.88	0.05	79.02	0.65	0.26	67.62	0.56	0.42
Test 3	95.86	0.91	0.04	80.02	0.68	0.22	68.33	0.57	0.43



(a) 鲁甸数据集



(b) 玉树数据集

图 2-7 不同区域建筑物示例

Fig.2-7 Examples of buildings in different areas

通过对一些区域的预测结果进行可视化定性分析能够直观地了解模型在建筑物损毁精细化评估中的情况。在本研究中，将影像分割成小块，而不是单个建筑物的分割。因此，一个 patch 可能包含多个建筑物。当建筑物被裁剪为两个或多个 patch 时，建筑物的受损特征将保留在相应的 patch 中。将鲁甸数据集中训练好的 EBDC-Net 使用漾濞数据集进行微调。如图 2-8 所示，分别展示了漾濞数据集中的原始影像、模型评估的可视化结果和目视解译的结果。从实验评估结果能够看出，模型的评估结果与目视解译的结果基本一致，总体精度为 75%、kappa 为 0.66、MSE 为 0.26。另外，还评估了利用无人机影像进行建筑物损毁评估所需要的时间。

结果显示对于一张 5474×3648 像素大小的无人机影像，需要的平均处理时间为 19s，能够满足建筑物损毁快速评估的需要。




Fig.2-8 Visualization of evaluation results in Yangbi dataset

2.4 本章小结

为了快速准确地评估震后建筑物的损毁程度，本研究提出了一个用于建筑损毁分类的 EBDC-Net 网络。EBDC-Net 主要由特征提取模块和建筑物损毁分类模块组成。首先，在 EBDC-Net 的特征提取模块中引入了空间注意力机制聚集影像中相似的建筑物损毁特征，增强了网络的特征表示能力。其次，在 EBDC-Net 的建筑物损毁分类模块中构建了全局特征提取和上下文特征提取模块。综合利用影像

中的全局特征和上下文特征，增强网络对建筑物周围的纹理信息和空间结构的区分能力，提高建筑物损毁分类的精度。为了评估 EBDC-Net 模型的有效性，在鲁甸数据集和玉树数据集中与其他四种最先进的建筑物损毁分类方法进行了比较，EBDC-Net 展现出了最好的分类精度。在两个数据集中，对于 Group1 中的分类标准模型的总体精度分别为 94.44%和 94.72%，对于 Group2 中的分类标准模型的总体精度分别为 85.53%和 79.02%，对于 Group3 中的分类标准模型的总体分类精度分别为 77.49%和 67.62%。其次，讨论了 EBDC-Net 中残差连接模块、空间注意力机制模块和上下文特征提取模型对建筑物损毁分类精度的贡献。另外，结合鲁甸数据集和玉树数据集探究了历史地震数据在未来地震中的作用。实验结果表明，利用历史地震数据初始化训练模型有助于在未来的地震中更好的评估建筑物的损毁程度。最后，在漾濞数据集中进行的大范围损毁评估测试表明，EBDC-Net 能够快速的对受灾区域的建筑物进行损毁分类。

第3章 基于YOLOv4和多源数据融合的船舶目标分类

为了提高单源数据下船舶目标的分类精度，本研究提出了一种多源数据决策级融合船舶目标分类方法。该方法的总体流程如图3-1所示。该方法主要包含多源影像生成模块、单信源船舶分类模块和多信源决策级融合分类模块。在多源影像生成模块中，利用CycleGAN模型构建了OPT-SAR影像转化模型实现光学影像到SAR影像的转换，建立了多源遥感影像船舶分类数据集。在单信源船舶分类模块中，构建了基于YOLOv4的船舶分类模型，分别从SAR和光学影像中识别出所有类型的船舶。在多信源决策级融合分类模块中，提出了一种自适应加权的决策级融合分类模型对不同信源的分类结果进行决策级融合，提升船舶分类的精度。




图 3-1 海面船舶目标决策级融合分类方法流程图

Fig.3-1 The framework of decision-level fusion classification method for sea ships

3.1 OPT-SAR 影像转换模型

相较于 Pix2Pix 而言，CycleGAN 可以很好的保留影像的结构信息^[51]。CycleGAN 采用无监督的方式进行训练，并且 CycleGAN 对训练的数据要求比 Pix2Pix 模型更低，无需训练数据在源域和目标域之间有严格的配对关系，就能实现不同数据域之间的影像转换^[49]。尽管 CycleGAN 网络在没有监督的情况下进行训练，但多项任务的定性结果表明 CycleGAN 的性能接近 Pix2Pix^[49]。因此，本研

究利用 CycleGAN 建立光学影像到 SAR 影像的转换模型，以获取成对的光学-SAR 船舶分类影像。




图 3-2 CycleGAN 网络模型

Fig.3-2 CycleGAN network model

如图 3-2 (a) 所示，CycleGAN 能够学习给定训练样本 $\{x_i\}_{i=1}^N \in X$ 和 $\{y_i\}_{i=1}^M \in Y$ 两个域之间的映射函数 $G: X \rightarrow Y$ 和 $F: Y \rightarrow X$ 。生成器 G 将一个图像 $x \in X$ 从域 X 转换到域 Y ，生成器 F 将一个图像 $y \in Y$ 从域 Y 中转换到域 X 。判别器 D_Y 用于判别一个图像是否为真实的域 Y 内图像。同样地，判别器 D_X 用于判别一个图像是否为真实的域 X 内图像。生成器的目标是 minimized 生成的图像与真实图像之间的距离，同时欺骗判别器，使其将生成的图像误认为是真实的域内图像；而判别器的目标则是 minimized 分类误差，同时尽可能地准确地判别出真实和生成的图像。为了保持图像转换的一致性，CycleGAN 还引入了循环一致性损失。如图 3-2 (b) 所示，将一个域 X 中的图像转换为域 Y 中的图像，再将生成的图像转换回域 X ，应该得到与原始图像相似的图像即 $x \rightarrow G(x) \rightarrow F(G(x)) \approx x$ 。类似地，如图 3-2 (c) 所示，对于域 Y 中的图像有 $y \rightarrow F(y) \rightarrow G(F(y)) \approx y$ 。这种损失可以通过计算原始图像和经过两次转换后的图像之间的像素级差异来实现。

CycleGAN 的损失函数可以分为两个部分：对抗损失和循环一致损失。对于生成器 $G(x)$ 和判别器 D_Y 的对抗性损失定义如式 3-1 所示：

$$\begin{aligned} \mathcal{L}_{GAN}(G, D_Y, X, Y) = & \mathbb{E}_{y \sim P_{data}(y)} [\log D_Y(y)] \\ & + \mathbb{E}_{x \sim P_{data}(x)} [\log (1 - D_Y(G(x)))] \end{aligned} \quad (3-1)$$

其中, G 将尝试生成与 Y 域影像相似的影像 $G(x)$, 而 D_Y 旨在区分生成影像 $G(x)$ 和真实影像 Y 。类似地, 对于生成器 $F(y)$ 与判别器 D_X 的对抗损失为 $\mathcal{L}_{GAN}(F, D_X, Y, X)$ 。

为了确保在执行图像转换时生成相应的样本, CycleGAN 在样本生成时利用了循环一致性损失, 定义如式 3-2 所示:

$$\begin{aligned} \mathcal{L}_{cyc}(G, F) = & \mathbb{E}_{x \sim P_{data}(x)} [\|F(G(x)) - x\|_1] \\ & + \mathbb{E}_{y \sim P_{data}(y)} [\|G(F(y)) - y\|_1] \end{aligned} \quad (3-2)$$

基于以上所述, 总的损失函数定义如式 3-3 所示:

$$\begin{aligned} \mathcal{L}(G, F, D_X, D_Y) = & \mathcal{L}_{GAN}(G, D_Y, X, Y) \\ & + \mathcal{L}_{GAN}(F, D_X, Y, X) \\ & + \lambda \mathcal{L}_{cyc}(G, F) \end{aligned} \quad (3-3)$$

其中, 超参数 λ 对循环一致性损失进行加权来创建完整的目标损失函数。




图 3-3 OPT-SAR 多源影像生成模型框架图

Fig.3-3 The framework of OPT-SAR multi-source images generated model

本研究中的多源影像生成模型如图 3-3 所示。需要定义两个域, 一个光学影像域 X 和一个 SAR 影像域 Y 。首先, 利用 CycleGAN 模型学习 SAR 域与光学域之

间的映射函数，建立光学影像到 SAR 影像的 OPT-SAR 影像转换模型。然后通过 OPT-SAR 模型将光学影像转换为伪 SAR 影像从而获取匹配的多源遥感影像，构建多源遥感影像船舶分类数据集。最后，通过真实的 SAR 影像与生成的伪 SAR 影像对 OPT-SAR 转换模型进行影像质量评估，以验证该模型生成影像的有效性和泛化性。本研究中使用 OPT-SAR 转换模型的生成器 $G(x)$ 将光学影像转换成 SAR 影像。为了使得 OPT-SAR 影像转换模型能够学习到不同的地物类型和船舶特征，如图 3-4（a）和图 3-5（a）所示，光学域中的影像中包含了不同地物类型和不同类别船舶的光学影像。同样地，如图 3-4（b）和图 3-5（b）所示，SAR 域中也包含了不同的地物类型和不同类别船舶的 SAR 影像。




图 3-4 包含不同地物类型的多源遥感影像

Fig.3-4 Multi-source remote sensing images containing different types of ground objects




图 3-5 包含不同类别船舶的多源遥感影像

Fig.3-5 Multi-source remote sensing images containing different ship targets

3.2 基于 YOLOv4 的船舶分类算法

YOLOv4 作为一种先进的目标分类识别模型。采用了空间金字塔池化（SPP）、路径聚合网络（PANet）提升了对小目标和多尺度目标的识别能力。在保持精度的同时减少了计算量，是目前实现速度与精度平衡的最佳目标分类识别模型之一。因此本研究使用 YOLOv4 作为船舶目标分类识别的基线模型。

本文提出的改进 YOLOv4 船舶分类模型如图 3-6 所示，该模型主要包含特征编码模块和特征解码模块。在特征编码模块中，使用 CSPDarknet53 作为主干网络。为了提升对不同尺度船舶目标的分类精度，在主干网络后构建了一个空间金字塔池化模块。该模块通过使用不同大小的卷积核对主干网络提取的特征进行池化操作，能够扩大模型的感受野，提升网络对不同尺度船舶目标的提取能力，分离出船舶的显著特征。其次，路径聚合模块对主干网络提取的高、中、低三个层级的特征进行自下到上和自上到下的充分融合，充分利用了不同尺度特征层的信息，提升网络对不同尺度船舶目标的分类精度。在解码模块中，对特征提取模块中输出的三个层次特征进行解码，解码的过程中在原有的预测头中对输出的预测框的坐标进行高斯建模，评估预测框的可靠性，减少预测框的假阳性。最后，对三个尺度预测头输出的预测框采用非极大抑制等后处理技术进行处理，获得船舶目标最终的分类结果。




图 3-6 YOLOv4-Gaussian 船舶分类模型

Fig.3-6 YOLOv4-Gaussian ship classification model

在 YOLOv4 船舶分类模型中，模型输出的预测框信息仅包含其中心坐标、宽度和高度，没有对预测框定位的可靠性进行判断，无法得知预测框的可靠性。由于错误的定位会导致分类时假阳性的增加，影响船舶分类的精度。尤其是对于背景复杂的遥感影像来说，预测框定位的可靠性判定是必要的。因此，本研究中引入高斯模型^[75]来弥补这一缺陷，利用高斯分布特性来评估每个预测框的可靠性。提升船舶目标分类时的真阳性（TP），同时降低分类时的假阳性（FP），提高遥感影像中船舶分类的精度。并且高斯模型的引入几乎不会增加模型的计算量^[75]。




图 3-7 预测框属性

Fig.3-7 Attributes of the prediction box

如图 3-7（a）所示，在 YOLOv4 模型输出的预测框信息中，主要信息包括 $x, y, w, h, o_{score}, c_{score}$ 。其中 x, y, w, h 分别代表预测框的中心坐标、宽和高， o_{score} 的值为 0 或 1，代表预测框中是否存在船舶目标， c_{score} 表示船舶目标属于每个类别的概率。在输出的信息中，预测框的坐标是一个确定的值，而非概率。因此，无法预知预测框的可靠性。预测框的可靠性可由坐标的信息（ x, y, w, h ）和高斯模型进行建模。将每个预测框的坐标建模为均值和方差。对一个简单的高斯模型而言，输入测试 x ，输出 y 的高斯模型表示如式 3-4 所示：

$$p(y|x) = N(y; \mu(x), \Sigma(x)) \quad (3-4)$$

其中 $\mu(x)$ 和 $\Sigma(x)$ 分别是均值和方差函数。引入高斯模型后输出的预测框坐标信息为 $\hat{\mu}_x, \hat{\Sigma}_x, \hat{\mu}_y, \hat{\Sigma}_y, \hat{\mu}_w, \hat{\Sigma}_w, \hat{\mu}_h, \hat{\Sigma}_h$ ，结合 YOLOv4 的预测头结构，对 x, y, w, h 做如式 3-5、式 3-6 和式 3-7 的处理。

$$\sigma(x) = \frac{1}{(1 + \exp(-x))} \quad (3-5)$$

$$\mu_x = \sigma(\hat{\mu}_x), \mu_y = \sigma(\hat{\mu}_y), \mu_w = \hat{\mu}_w, \mu_h = \hat{\mu}_h \quad (3-6)$$

$$\Sigma_x = \sigma(\hat{\Sigma}_x), \Sigma_y = \sigma(\hat{\Sigma}_y), \Sigma_w = \sigma(\hat{\Sigma}_w), \Sigma_h = \sigma(\hat{\Sigma}_h) \quad (3-7)$$

如图 3-7 (b) 所示对预测框坐标进行高斯建模后, 输出的预测框信息为 $\mu_x, \Sigma_x, \mu_y, \Sigma_y, \mu_w, \Sigma_w, \mu_h, \Sigma_h, O_{score}, C_{score}$ 。其中均值代表预测框的新坐标, 方差代表每个预测框的不确定性。然后通过式 3-8 对输出的预测框进行过滤, 其中 $\sigma(O)$ 表示预测框中是否存在船舶的概率, $\sigma(C_i)$ 表示船舶属于第 i 个类别的概率, U_{aver} 表示预测框坐标不确定性的平均值。通过过滤能够得到高可信度的预测框, 提高船舶识别时的 TP, 降低船舶识别时的 FP, 从而提高船舶分类的精度。

$$Cr_i = \sigma(O) \times \sigma(C_i) \times (1 - U_{aver}) \quad (3-8)$$

由于在 YOLOv4 中使用了高斯模型对预测框的坐标进行建模, 模型的损失函数进行了相应的修改, 表示如式 3-9 所示:

$$L_x = - \sum_{i=1}^W \sum_{j=1}^H \sum_{k=1}^K \gamma_{ijk} \log(N(x_{ijk}^G | \mu_x(x_{ijk}), \Sigma_x(x_{ijk})) + \varepsilon) \quad (3-9)$$

其中 L_x 是 x 坐标的 NLL 损失, L_y, L_w, L_h 与 L_x 相同。 W 和 H 代表影像的宽和高。

$\mu_x(x_{ijk})$ 是预测头的输出, 代表在第 (i, j) 网格中的第 k 个 anchor 处的 x 坐标值。

$\Sigma_x(x_{ijk})$ 同样是预测头的输出, 表示预测框中心点坐标 x 的置信度。 x_{ijk}^G 代表 x 坐标的 GT 值。

3.3 基于自适应加权的多源决策级融合分类算法

使用多源数据进行船舶目标决策级融合分类可以有效地融合不同单源数据的优势, 提高船舶分类的精度。与现有的大多数研究中通过人工选择或者依赖先验信息来确定不同数据源分类结果的权重不同, 本文提出了一种自适应加权的决策级融合分类算法来融合不同数据源下的分类结果以提升船舶分类的精度。该算法主要包含船舶目标匹配和决策融合分类两个过程。

由于 SAR 和光学两种船舶分类模型的输出结果各不相同, 因此在进行多源数据决策级融合分类之前需要对 SAR 影像和光学影像中识别到的船舶目标进行匹配。不同数据源下的船舶目标可以看作是二部图中的点, 而 Kuhn-Munkres (K-M) 算法^[76]通常被用于解决带权二部图的最优匹配问题。因此, 本文利用 K-M 算法建立船舶目标全局最优匹配模型。

在进行船舶目标全局最优匹配时，将数据源 1 中所识别到的船舶目标视为集合 X ，将数据源 2 中所识别到的船舶目标视为集合 Y 。计算 X 与 Y 中目标间的 IOU，将 IOU 值作为两个目标间的距离权重。给定一个完全二部图 $G = (V, E)$ ，其中 $V = X \cup Y, E \in X \times Y, X \cap Y = \emptyset$ 。边 (x, y) 的权重为 $w(x, y)$ 。利用 K-M 匹配算法对不同数据源中船舶目标进行最优匹配。当某种数据源中出现目标漏检时，根据其他数据源的识别结果进行补充。基于 K-M 算法的船舶目标全局最优匹配算法运行流程如下所示：

本文的算法过程：

输入：船舶目标信息构建的二部图 $G = (V, E)$ 和距离权重矩阵 w 。

输出：船舶目标全局最优匹配序列。

第 1 步：初始化 G 。

第 2 步：计算 X 与 Y 目标间的 IOU，更新距离权重矩阵 w ：

$$w(x, y) = IOU(x, y) - 1$$

初始化顶点标号 l ：

对 X 中的每一个顶点：

$$lx = \max(w(x, y))$$

对 Y 中的每一个顶点：

$$ly = 0$$

第 3 步：从 G 的任一未匹配的顶点 l 开始，求出相等子图 G_l 。

第 4 步：对于图 G_l 的任意一个匹配 M ，将 X 中匹配 M 的非饱和点记为集合 A 。

第 5 步：若 $A = \emptyset$ ，输出 M ，转到第 8 步。

否则，任取 $x \in A$ ，记 $S := \{x\}, T := \emptyset$ ，转第 6 步

第 6 步：若 $N(S) \subseteq T$ ，不存在从 x 出发的 M 的增广路，令 $A := A - \{x\}$ ，转到第 5 步。

否则，取 $y \in N(S) - T$ ，转第 7 步。

第 7 步：若 y 是 M 的饱和，设 $yz \in M$ ，令 $S := S \cup \{z\}, T := T \cup \{y\}$ ，转到第 6 步。

否则，获得一条 M 增广路 $P(x, y)$ ，令 $M := M \oplus E(P), A := A - \{x, y\}$ ，转第 5 步。

第 8 步：若找到图 G_l 的一个完美匹配 M ，则输出该匹配，停止算法。

否则， $S \subset X, T \subset Y$ ，且 $N_{G_l}(S) = T$ ，转到第 9 步。

第 9 步：计算 α_l ，计算 G 的新的可行顶点编号 l' ，以 l' 代替 l ， G' 代替 G ，转到第 8 步。

$$\alpha_l = \min\{l(x) + l(y) - w(x, y) \mid x \in S, y \in Y - T\}$$

$$l'(u) = \begin{cases} l(u) - \alpha_l, u \in S \\ l(u) + \alpha_l, u \in T \\ l(u), \text{其他} \end{cases}$$

在决策级融合分类前，假设有 J 种数据源， K 种船舶类别。对影像中的第 i 个船舶目标而言，在第 j 种数据源中被识别为第 k 种类别的概率为 $p_{i,k,j}$ 。经过 J 种数据源决策级融合后被识别为第 k 种类别的概率为 $P_{i,k,J}$ 。在决策级融合中，对第 i 个目标而言，当模型输出结果的置信度越大，该模型的识别结果被信任的可能性应该越大，在融合判定时，该判定结果所占权重就越大。在本研究中，不同模型判定结果所占有的权重是由模型本身的判定结果所决定，以此来增加模型的可适用性。融合的核心思想是经过 J 种不同数据源融合判断后船舶目标被识别为各类别的概率通过式 3-10 进行确定。

$$P_{i,k,J} = \begin{cases} P_{i,k,J-1} + (1 - P_{i,k,J-1})p_{i,k,j}, & 1 \leq J, j = J \\ 0, & J = 0 \end{cases} \quad (3-10)$$

在式 3-10 中，当 $P_{i,k,J-1}$ 越大时， $p_{i,k,j}$ 相应所占的权重就越小，反之亦然，这是一个自适应动态的调整过程。如式 3-11 与 3-12 所示，决策级融合后船舶目标判定为类别 k 的概率处于 0 和 1 之间，并且大于单信源下的置信度。

$$P_{i,k,J} \geq P_{i,k,j}, 1 \leq J, 1 \leq j \leq J \quad (3-11)$$

$$0 \leq P_{i,k,J} \leq 1 \quad (3-12)$$

决策融合判定后，第 i 个船舶目标的识别类别和相应概率可由式 3-13 得到，判定公式为：

$$P_i = \operatorname{argmax} P_{i,k,J}, 1 \leq k \leq K \quad (3-13)$$

3.4 实验数据

为了训练光学影像到 SAR 影像的 OPT-SAR 影像转换模型，在本研究中，从 SEN1-2 数据集^[50]中选取了 1600 对 SAR-光学匹配对影像，其中训练集 1280 张，验证集 160 张，测试集 160 张。由于 SEN1-2 数据集中只包含不同的地物类型，影像中没有包含船舶信息。因此，本研究从 HRSC2016 数据集^[21]中选取了 1000 张包含船舶的光学影像加入光学域，从 SSDD^[45]数据集中选取了 1000 张包含船舶的 SAR 影像加入 SAR 域，使得 OPT-SAR 影像转换模型能够学习船舶目标在光学和 SAR 域中的特征信息。

为了构建 L2 级多源遥感影像船舶分类识别数据集，本研究从 HRSC2016 数据集中选取了符合 L2 级船舶分类要求的影像 414 张，包含近岸、港口、岛礁和云四种实际场景。在这些影像中包含五个船舶类别：Frigate、Destroyer、Amphibious、Cruiser 和 Aircraft carrier。由于原始数据集中的船舶大多停泊在港口。因此，在本研究中将船舶的掩膜放入到不同的场景的影像中，模拟不同的海况，提升模型在不同海况下的分类识别性能。对于云雾这种特殊场景，首先将不受云雾影响的光学影像使用 OPT-SAR 影像转换模型转换为相应的 SAR 影像，然后将云雾的掩膜加入光学影像中，以此来模拟云雾场景下的光学影像和 SAR 影像。如图 3-8 所示，使用训练好的 OPT-SAR 影像转换模型将光学影像转换为伪 SAR 影像以获取匹配的光学-SAR 影像。为了对数据集进行扩充，模型训练时使用了旋转、色调、饱和度和光照度进行数据增强。




图 3-8 多源遥感影像船舶分类数据集

Fig.3-8 Multi-source remote sensing image ship classification dataset

3.5 实验结果与分析

3.5.1 OPT-SAR 转换模型影像生成结果

如图 3-9 所示，展示了本研究中基于 CycleGAN 构建的 OPT-SAR 影像转换模型将 SEN1-2 数据集中的光学影像转换为伪 SAR 影像的示例结果。将生成的伪 SAR 影像与真实的 SAR 影像相比较，生成的伪 SAR 影像保持了影像的整体结构，海陆的分割线清楚，能够反映出地表物体的形态和纹理特征。同时，生成的伪 SAR 影像也具有真实 SAR 影像的散斑噪声。因此，本研究中构建的 OPT-SAR 影

像转换模型展现出了较好的性能，能够将光学影像转换成匹配的 SAR 影像，从而构建多源船舶分类数据集。

为了定量评估 OPT-SAR 模型生成的模拟影像质量，本研究使用结构相似性指数测度 (SSIM)^[77]、峰值信噪比 (PSNR)^[77] 和 Frechet inception 距离 (FID)^[77] 对 OPT-SAR 影像转换模型的性能进行评价。SSIM 综合了亮度、对比度和结构信息，能够量化地评估两个图像之间的相似程度。SSIM 的值在 0 和 1 之间，值越接近 1 表示两个图像越相似。PSNR 用于比较真实图像和生成的图像之间的相似性。PSNR 值越高代表生成的影像质量越好。FID 是一种用于比较两个图像集合相似性的指标。该指标在特征空间上评估生成的图像集合与真实的图像集合的距离和重叠程度。FID 值越低，表示生成的影像越接近真实的影像。在本研究中，OPT-SAR 影像转换模型在测试集上的 SSIM 值为 0.04、PSNR 值为 11.86、FID 值为 163.27。根据现有的光学影像与 SAR 影像相互转换的研究^[51, 52]结果，本研究中这些指标的值是合理有效，表明本研究中所构建的多源数据生成方法是合理有效的。




图 3-9 OPT-SAR 转换模型生成的伪 SAR 影像

Fig.3-9 Pseudo-SAR image generated by OPT-SAR translation model

在影像转换的过程中，由于在光学影像中水体和山体在颜色、对比度和亮度方面比较相似，导致了 OPT-SAR 影像转换模型在进行影像转换时区分水体和水体的性能下降。如图 3-9 所示，山体和水体在转换后的影像中展现出了相似的特征，导致了评估结果中的 SSIM 值较低。总的来说，基于 CycleGAN 的 OPT-SAR 影像转换模型是一种将光学影像转换为 SAR 影像的有效方法。当没有可用的 SAR 遥感数据时，生成的伪 SAR 影像能够为多源数据融合研究提供支持。

3.5.2 单源数据船舶分类结果

本研究首先比较了不同基线模型在船舶分类中的性能，主要包含 SSD、Faster R-CNN、YOLOv3、YOLOv4 模型。如表 3-1 所示，展示了不同基线模型在 SAR 和光学数据源下船舶的分类识别精度。通过计算每个船舶类别精度的平均值（mAP）来衡量船舶分类识别模型的性能。在不同的基线模型中，YOLOv4 展现出了最高的识别精度。在 SAR 数据源中的 mAP 为 76.58%，光学数据源中的 mAP 为 83.70%。首先，这得益于 YOLOv4 拥有更深的主干特征提取网络，能够提取更丰富的船舶信息。并且对主干网络提取的不同尺度的特征层进行了融合，提升了模型对不同尺度船舶目标的分类精度。

表 3-1 不同模型在不同数据源上的船舶分类精度

Tab.3-1 Classification accuracy of different models under different data sources

模型名称	SAR (%)			光学 (%)		
	Precision	Recall	mAP	Precision	Recall	mAP
SSD	76.75	57.64	54.35	80.73	70.10	66.40
Faster R-CNN	73.61	73.71	66.72	82.45	83.28	78.82
YOLOv3	77.28	64.10	62.07	84.71	72.00	73.38
YOLOv4	80.13	77.71	76.58	77.11	86.00	83.70
YOLOv4-Gaussian	83.30	78.10	78.89	86.00	87.63	86.85

在 YOLOv4 中引入高斯模型后，在 SAR 和光学数据源中的船舶分类识别精度进一步提高了大约 3.00%。在 SAR 数据源下的 mAP 为 78.89%，光学数据源下的 mAP 为 86.85%。如图 3-10（a）和图 3-10（b）所示，橙色椭圆标注的为未识别到的船舶目标。在复杂的港口环境中，YOLOv4-Gaussian 模型对预测框的定位进行了可靠性的判断，从而能够识别到 YOLOv4 模型没有识别到船舶目标，进而提

高了船舶目标分类时的 TP 值。另外，如图 3-10 (c) 和图 3-10 (d) 所示，紫色椭圆标注的为误分类船舶目标，YOLOv4-Gaussian 模型相比 YOLOv4 模型而言，对船舶目标的分类更加准确，能够减少船舶分类时的 FP 值。




图 3-10 YOLOv4 与 YOLOv4-Gaussian 分类结果比较

Fig.3-10 Comparison of classification results between YOLOv4 and YOLOv4-Gaussian

如表 3-2 所示，展示了在测试集上 YOLOv4 和 YOLOv4-Gaussian 模型的 TP 和 FP 的统计结果。在 SAR 和光学数据源下，TP 值分别增加了 3.82%和 2.33%，FP 值分别减少了 15.69%和 56.62%。因此，在不同数据源和复杂的海况下通过预测框坐标进行高斯建模，判断其可靠性能降低船舶分类时的 FP 和提高 TP，进而提升船舶分类的精度。

表 3-2 YOLOv4 与 YOLOv4-Gaussian 模型在测试集上的 TP 和 FP 统计结果

Tab.3-2 Statistical results of TP and FP of YOLOv4 and YOLOv4-Gaussian in the testset

指标	SAR			光学		
	YOLOv4	YOLOv4-Gaussian	变化率 (%)	YOLOv4	YOLOv4-Gaussian	变化率 (%)
GT	197	197	-	197	197	-
TP	157	163	+3.82	172	176	+2.33
FP	51	43	-15.69	83	36	-56.62

3.5.3 不同决策级融合方法分类结果比较

为了验证本文提出的船舶目标决策级融合分类方法的性能，将所提出的自适应加权决策级融合分类模型与现有最先进的决策级融合分类方法进行比较。比较的方法包括基于决策模板的融合方法^[60]和固定加权的决策融合方法^[56]。本文提出的自适应加权决策级融合分类算法的船舶分类结果如表 3-3 所示。对于大多数的船舶类别，分类的准确率高于 85.00%。其中，Destroyer 和 Aircraft carrier 两个船舶类别的分类精度最高，准确率分别为 95.20%和 92.79%。Amphibious 和 Frigate 两个船舶类别的识别分类精度略低于 Destroyer 和 Aircraft carrier 两个类别，分别为 88.74%和 87.94%。Cruiser 在所有类型的船只中显示出最低的精度，但准确度高于 80%。

表 3-3 不同决策级融合方法的船舶分类精度

Tab.3-3 Ship classification accuracy of different decision level fusion methods

船舶类别	AP (%)		
	决策模板	固定加权	自适应加权
Aircraft carrier	91.02	92.69	92.79
Amphibious	86.97	85.48	88.74
Cruiser	81.78	81.00	82.62
Destroyer	94.46	95.44	95.20
Frigate	84.82	85.84	87.94
mAP	87.81	88.09	89.46

在不同的决策级融合分类方法中，本文提出的自适应加权决策级融合分类方法的分类准确率最高，精度为 89.46%。比基于决策模板的决策级融合分类方法精

度高 1.65%，比基于固定权重的决策级融合分类方法精度高 1.37%。具体到每个船舶类别而言，自适应加权方法在除 Destroyer 以外的其他四个船舶类别中均取得了最好的分类精度。对于 Destroyer 船舶类别，本文所提出的方法比固定加权的融合分类方法低 0.24%。




图 3-11 不同决策级融合方法融合分类效果对比

Fig.3-11 Comparing the classification results of different decision level fusion methods

如图 3-11 (a) 和图 3-11 (b) 所示，蓝色椭圆标注的为重复识别的船舶目标。在像港口这种船舶分布密集的场景中，基于决策模板的融合方法在融合时对不同数据源下所得到的预测框按照置信度与重叠度大小进行过滤，存在重叠度阈值设定困难，进而导致融合时存在船舶目标的重复识别，影响船舶的分类精度。如图 3-11 (c) 和图 3-11 (d) 所示，紫色椭圆标注的为分类错误的船舶目标。在背景复杂的场景中，当同一船舶目标在不同数据源中的分类识别结果不同时，由于固定权重的决策级融合方法不同分类器的权重是预先设定的值，导致模型的鲁棒性较低，不能正确的纠正船舶目标的错误分类。本文中所提出的自适应加权的决策级融合方法在融合判定前会对不同数据源下的船舶识别结果进行最优匹配，能够

降低融合时船舶目标的重复识别问题。在融合判定时根据单源数据下模型自身的分类精度自适应地调整不同数据源下分类结果在融合时所占的权重，增加模型在不同场景下的自适应能力，提高船舶的分类精度，增加模型的鲁棒性。

3.5.4 多源数据对船舶分类精度的影响

为了评估多源数据对船舶分类精度的影响，本研究进一步比较了决策级融合前后船舶的分类精度。如表 3-4 所示，在使用 SAR 和光学数据对进行融合分类后，每个船舶类别的分类精度都有显著的提高，比仅使用 SAR 影像时高 10.57%，比仅采用光学影像时高 2.61%。具体而言，与仅使用 SAR 影像相比，使用所提出的决策级融合方法在所有船舶类别中都显著提高了精度，尤其是对于 Frigate、Amphibious 和 Aircraft carrier 三个类别船舶的分类精度。与仅使用光学影像相比，船舶的分类精度也有所提升，但不如 SAR 影像中显著。

如图 3-12 所示，橙色椭圆标注的为未识别到的船舶目标。由于 SAR 影像中的噪声较多，导致模型在港口这类复杂场景中出现船舶目标的漏检。而光学影像具有更加丰富的细节信息。通过使用多源数据进行决策级融合分类可以弥补单源数据下船舶目标的漏检问题，并提高船舶目标分类的准确性。




图 3-12 融合前后船舶分类效果对比

Fig.3-12 Comparison of ship classification effects before and after fusion

表 3-4 决策级融合前后的船舶分类精度

Tab.3-4 Ship classification accuracy before and after decision-level fusion

船舶类别	数据源 AP (%)			提升(%)	
	SAR	光学	多源融合分类	相对于 SAR	相对于光学
Aircraft carrier	81.15	89.78	92.79	11.64	3.01
Amphibious	71.91	86.86	88.74	16.83	1.88
Cruiser	76.68	81.18	82.62	5.94	1.44
Destroyer	94.63	91.48	95.20	0.57	3.72
Frigate	70.11	84.96	87.94	17.83	2.98
mAP	78.89	86.85	89.46	10.57	2.61

3.5.5 不同海况对船舶分类精度的影响

考虑到不同海况下影像背景的复杂程度可能会影响船舶目标的分类精度。为了评估本研究中所提出的决策级融合分类模型在不同海况下的有效性，在薄厚云、港口、近海和岛礁四种不同的海况下进行了实验。




图 3-13 薄厚云海况下融合前后船舶分类效果对比

Fig.3-13 Comparison of classification effects before and after fusion under cloud sea condition

薄厚云海况下的比较结果如图 3-13 所示, 橙色椭圆标注的为漏检船舶目标。由于光学传感器对天气成像条件敏感, 在薄厚云的海况下, 船舶会被云层遮挡, 导致了在光学影像中出现船舶目标的漏检。然而 SAR 传感器能够穿透云层, 因此在薄厚云海况下利用 SAR 传感器穿透云雾的特性, 通过决策级融合分类降低了光学影像的漏检率, 提高船舶分类的精度。

如图 3-14、图 3-15 和图 3-16 所示, 分别展示了港口、近岸和岛礁海况下融合前后船舶分类效果的对比, 橙色椭圆标注的为漏检船舶目标, 紫色椭圆标注的为误分类船舶目标。在港口、近岸和岛礁这类复杂海况中, 受到地物多样性和海陆分割线的影响, 传感器成像时会有较大的噪声, 船只目标很容易与背景混淆。在船舶的分类中出现较高的误分类和低置信度。由于光学影像包含的空间纹理信息更加丰富, 因此模型在光学影像中的船舶分类结果要优于 SAR 影像中的分类结果。利用光学影像丰富的光谱和纹理信息弥补 SAR 影像细节信息的不足, 使用本文提出的自适应加权决策级融合分类方法能够提高复杂海况下船舶的分类精度。

在四种海况下, 模型在光学影像中的分类效果优于 SAR 影像的分类效果, 而 SAR 影像能够在薄厚云的海况下为光学影像提供辅助, 光学影像能够在复杂的地理环境中为 SAR 影像提供更丰富的空间和光谱信息。通过对两种影像下的分类结果进行决策级融合判定, 能够提高模型在不同海况下对船舶的分类识别能力。实验结果表明本文所提出的决策级融合分类方法在复杂的海况下具有较强的鲁棒性。




图 3-14 港口海况下融合前后船舶分类效果对比

Fig.3-14 Comparison of ship classification effects before and after fusion in port sea condition




图 3-15 近岸海况下融合前后船舶分类效果对比

Fig.3-15 Comparison of ship classification effects before and after fusion in offshore sea condition




图 3-16 岛礁海况下融合前后船舶分类效果对比

Fig.3-16 Comparison of ship classification effects before and after fusion in reef sea condition

3.6 本章小结

由于在船舶分类识别任务中单一数据源的局限性，很难满足不同海况下船舶分类识别的需求。针对在光学和 SAR 影像中的决策级融合分类识别问题，本文提

出了一种基于深度学习的多源遥感影像船舶目标决策级融合分类识别方法。所提出的方法利用多源数据的优势提升了船舶目标分类的精度。首先,为了解决船舶目标分类识别时多源异构匹配影像难以获取的问题,本文基于 CycleGAN 网络构建了 OPT-SAR 影像转换模型将光学影像转换为匹配的 SAR 影像,并建立了一个用于船舶目标融合分类的多源遥感影像数据集。其次,对 YOLOv4 船舶分类模型中输出的预测框坐标进行高斯建模,提高了预测框的可靠性。然后分别从 SAR 和光学影像中识别所有类型的船舶,提高了单一数据源下船舶的分类精度。最后,建立自适应加权决策级融合方法对不同数据源的分类结果进行决策级融合,发挥多源数据的优势,进一步提升船舶分类的精度,解决了不同复杂环境下的船舶分类识别问题。为了评估所提出方法的有效性和鲁棒性,与四种最先进的决策级融合方法进行了比较,所提出的自适应加权决策级融合分类方法表现出最高的准确性。此外,比较了使用单源数据和多源数据时的船舶分类精度,探讨了多源数据在船舶分类中的作用,以及模型在不同海况下的性能表现。与仅使用 SAR 影像和光学影像相比,船舶目标的分类精度分别提高了 10.57%和 2.61%。实验结果表明通过使用所提出的决策级融合分类模型,可以提高船舶分类的准确性。

第4章 总结与展望

针对建筑物地震损毁分类和多源数据船舶目标决策级融合分类问题，本文的主要工作和创新如下：

针对现有的大多数研究将建筑物分为完好和倒塌两个类别，不能满足救援和灾后损毁精细化评估需要的问题。在本文中，提出了一种名为 EBDC-Net 的网络来解决地震后受损建筑物的精细化分类问题。EBDC-Net 主要由建筑物损毁特征编码器模块和建筑物损毁分类模块构成。在特征编码模块中，通过残差结构加深了网络的深度，同时降低了输入影像尺寸较小带来的特征丢失问题。另外，通过空间注意力机制对影像中分散的损毁特征进行聚集，提高网络对损毁特征的表示能力，增强网络对不同损毁等级建筑物的区分能力。在建筑损毁分类模块中，通过全局特征提取模块探索影像中的全局损毁特征信息。其次，通过上下文特征提取模块探索影像不同区域特征之间的联系，充分利用影像中不同区域中的纹理特征信息。为了验证模型的实用性和鲁棒性，本文在鲁甸、玉树和漾濞三个地震数据集上进行了比较。实验结果表明在鲁甸和玉树数据集中，与最先进的建筑物损毁分类方法相比，本文提出的方法的精度至少高 1.92%和 2.57%。引入上述三种策略后，建筑物的损毁分类精度在鲁甸和玉树数据集中分别提高了 3.26%和 2.43%。其次，探讨了 EBDC-Net 在不同分类标准中建筑物损毁分类的精度。实验结果表明，EBDC-Net 在不同的分类标准中均展现出了最好的性能，能够满足建筑物地震损毁精细化评估的需要。最后，结合漾濞数据集讨论了历史地震数据对地震损毁评估的作用。利用历史地震数据和微调模型对未来地震中受损的建筑物进行快速分类是一种很好的策略。

针对单源船舶目标分类精度低和鲁棒性低的问题，本研究提出了一种基于深度学习的多源遥感影像船舶目标决策级融合分类方法。首先，构建了一个基于 CycleGAN 的 OPT-SAR 影像转换模型，将光学影像转换为匹配的 SAR 影像。并建立了一个多源遥感影像船舶分类数据集。然后，将高斯模型引入 YOLOv4 船舶目标分类模型。通过对预测框的坐标信息进行高斯建模，提高了预测框的可靠性，降低了船舶分类识别时的假阳性，从而提高了单源数据下船舶目标的分类精度。最后，提出了一种新的自适应加权决策级融合分类算法融合来自不同数据源的分类结果，提高模型在不同海况下的分类精度和鲁棒性。本研究通过与其他决策级融合分类方法的比较，评估了所提出的自适应加权决策级融合方法的优越性，结果表明，所提出的决策级融合分类方法具有最高的船舶分类精度。与仅使用 SAR 和光学影像相比，精度分别提高了 10.57%和 2.61%。此外，还探讨了该方法的鲁

棒性。结果表明，该方法即使在复杂环境下也具有良好的船舶分类识别能力。此外，所提出的自适应加权方法的主要思想也适用于其他对象，相信该模型将有助于未来相关的决策级融合研究。

针对建筑物地震损毁分类研究，目前仅使用了光学影像进行评估。未来，我们将使用多模态和多时相遥感影像进一步研究在复杂条件下建筑损毁的精细化评估。针对多源数据船舶目标决策级融合分类研究，所提出的方法的局限性在于，由于船舶目标的移动特性，仅使用两个不同的影像源进行决策级融合分类，这增加了获取多源影像的难度。这个问题将在未来的研究中通过结合无人机影像或其他卫星影像来解决。

参考文献

- [1]陈文凯. 面向震害评估的遥感应用技术研究 [D]; 中国地震局兰州地震研究所, 2007.
- [2]Ma H, Liu Y, Ren Y, et al. Improved CNN classification method for groups of buildings damaged by earthquake, based on high resolution remote sensing images [J]. Remote Sensing, 2020, 12(2): 260.
- [3]杜妍开, 龚丽霞, 李强, et al. 基于多纹理特征融合的震后 SAR 图像倒塌建筑物信息提取 [J]. 遥感技术与应用, 2021.
- [4]薛腾飞, 张景发, 李强. 基于相关变化检测与面向对象分类技术的多源遥感图像震害信息提取 [J]. 地震学报, 2016, 38(3): 10.
- [5]Zhang W, Tang P, Zhao L. Remote sensing image scene classification using CNN-CapsNet [J]. Remote Sensing, 2019, 11(5): 494.
- [6]Liu X, Deng Z, Yang Y. Recent progress in semantic image segmentation [J]. Artificial Intelligence Review, 2019, 52(2): 1089-106.
- [7]Zheng Z, Zhong Y, Wang J, et al. Building damage assessment for rapid disaster response with a deep object-based semantic change detection framework: From natural disasters to man-made disasters [J]. Remote Sensing of Environment, 2021, 265: 112636.
- [8]Wu C, Zhang F, Xia J, et al. Building damage detection using U-Net with attention mechanism from pre-and post-disaster remote sensing datasets [J]. Remote Sensing, 2021, 13(5): 905.
- [9]Xiao H, Peng Y, Tan H, et al. Dynamic Cross Fusion Network for Building-Based Damage Assessment; proceedings of the 2021 IEEE International Conference on Multimedia and Expo (ICME), F, 2021 [C]. IEEE.
- [10]Adriano B, Yokoya N, Xia J, et al. Learning from multimodal and multitemporal earth observation data for building damage mapping [J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2021, 175: 132-43.
- [11]Dong L, Shan J. A comprehensive review of earthquake-induced building damage

detection with remote sensing techniques [J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2013, 84: 85-99.

[12]Yang W, Zhang X, Luo P. Transferability of convolutional neural network models for identifying damaged buildings due to earthquake [J]. Remote Sensing, 2021, 13(3): 504.

[13]Duarte D, Nex F, Kerle N, et al. Multi-resolution feature fusion for image classification of building damages with convolutional neural networks [J]. Remote sensing, 2018, 10(10): 1636.

[14]Ji M, Liu L, Zhang R, et al. Discrimination of earthquake-induced building destruction from space using a pretrained CNN model [J]. Applied Sciences, 2020, 10(2): 602.

[15]Nex F, Duarte D, Tonolo F G, et al. Structural building damage detection with deep learning: Assessment of a state-of-the-art CNN in operational conditions [J]. Remote sensing, 2019, 11(23): 2765.

[16]Ishraq A, Lima A A, Kabir M M, et al. Assessment of Building Damage on Post-Hurricane Satellite Imagery using improved CNN; proceedings of the 2022 International Conference on Decision Aid Sciences and Applications (DASA), F, 2022 [C]. IEEE.

[17]Cao C, Liu D, Singh R P, et al. Integrated detection and analysis of earthquake disaster information using airborne data [J]. Geomatics, Natural Hazards and Risk, 2016, 7(3): 1099-128.

[18]Ci T, Liu Z, Wang Y. Assessment of the degree of building damage caused by disaster using convolutional neural networks in combination with ordinal regression [J]. Remote Sensing, 2019, 11(23): 2858.

[19]Matin S S, Pradhan B. Challenges and limitations of earthquake-induced building damage mapping techniques using remote sensing images-A systematic review [J]. Geocarto International, 2021: 1-27.

[20]Huang H, Sun G, Zhang X, et al. Combined multiscale segmentation convolutional neural network for rapid damage mapping from postearthquake very high-resolution images [J]. Journal of Applied Remote Sensing, 2019, 13(2): 022007.

- [21]Liu Z, Yuan L, Weng L, et al. A High Resolution Optical Satellite Image Dataset for Ship Recognition and Some New Baselines [Z]. Proceedings of the 6th International Conference on Pattern Recognition Applications and Methods. 2017: 324-31.10.5220/0006120603240331
- [22]Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector; proceedings of the European conference on computer vision, F, 2016 [C]. Springer.
- [23]Redmon J, Farhadi A. Yolov3: An incremental improvement [J]. arXiv preprint arXiv:180402767, 2018.
- [24]Bochkovskiy A, Wang C-Y, Liao H-Y M. Yolov4: Optimal speed and accuracy of object detection [J]. arXiv preprint arXiv:200410934, 2020.
- [25]Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2014 [C].
- [26]Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks [J]. Advances in neural information processing systems, 2015, 28: 91-9.
- [27]Jiang J, Fu X, Qin R, et al. High-Speed Lightweight Ship Detection Algorithm Based on YOLO-V4 for Three-Channels RGB SAR Image [J]. Remote Sensing, 2021, 13(10).
- [28]Fu H, Song G, Wang Y. Improved YOLOv4 Marine Target Detection Combined with CBAM [J]. Symmetry, 2021, 13(4).
- [29]Zhang T, Zhang X, Shi J, et al. HyperLi-Net: A hyper-light deep learning network for high-accurate and high-speed ship detection from synthetic aperture radar imagery [J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2020, 167: 123-53.
- [30]Kang M, Ji K, Leng X, et al. Contextual Region-Based Convolutional Neural Network with Multilayer Fusion for SAR Ship Detection [J]. Remote Sensing, 2017, 9(8).
- [31]Zhao L, Ji K, Leng X, et al. Squeeze and Excitation Rank Faster R-CNN for Ship Detection in SAR Images [J]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(5): 751-5.

- [32]Bentes C, Velotto D, Tings B. Ship classification in TerraSAR-X images with convolutional neural networks [J]. IEEE Journal of Oceanic Engineering, 2017, 43(1): 258-66.
- [33]Zhang T, Zhang X, Ke X, et al. HOG-ShipCLSNet: A Novel Deep Learning Network With HOG Feature Fusion for SAR Ship Classification [J]. IEEE Transactions on Geoscience and Remote Sensing, 2021: 1-22.
- [34]Ma M, Chen J, Liu W, et al. Ship classification and detection based on CNN using GF-3 SAR images [J]. Remote Sensing, 2018, 10(12): 2043.
- [35]Chen L, Shi W, Deng D. Improved YOLOv3 Based on Attention Mechanism for Fast and Accurate Ship Detection in Optical Remote Sensing Images [J]. Remote Sensing, 2021, 13(4).
- [36]Feng Y, Diao W, Sun X, et al. Towards Automated Ship Detection and Category Recognition from High-Resolution Aerial Images [J]. Remote Sensing, 2019, 11(16).
- [37]Zhang D, Zhan J, Tan L, et al. Comparison of two deep learning methods for ship target recognition with optical remotely sensed data [J]. Neural Computing and Applications, 2020, 33(10): 4639-49.
- [38]Zhang J. Multi-source remote sensing data fusion: status and trends [J]. International Journal of Image and Data Fusion, 2010, 1(1): 5-24.
- [39]Bai Q, Jin C. Image fusion and recognition based on compressed sensing theory [J]. International Journal on Smart Sensing and Intelligent Systems, 2015, 8(1): 159-80.
- [40]Ross A A, Govindarajan R. Feature level fusion of hand and face biometrics; proceedings of the Biometric technology for human identification II, F, 2005 [C]. International Society for Optics and Photonics.
- [41]Alipour Fard T, Hasanlou M, Arefi H. Classifier Fusion of High-Resolution Optical and Synthetic Aperture Radar (Sar) Satellite Imagery for Classification in Urban Area [J]. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2014, XL-2/W3: 25-9.
- [42]Useye J, Chen S. Comparative Performance Evaluation of Pixel-Level and Decision-

- Level Data Fusion of Landsat 8 OLI, Landsat 7 ETM+ and Sentinel-2 MSI for Crop Ensemble Classification [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(11): 4441-51.
- [43]Xian S, Zhirui W, Yuanrui S, et al. AIR-SARShip-1.0: High-resolution SAR ship detection dataset [J]. J Radars, 2019, 8(6): 852-62.
- [44]Wang Y, Wang C, Zhang H, et al. A SAR Dataset of Ship Detection for Deep Learning under Complex Backgrounds [J]. Remote Sensing, 2019, 11(7).
- [45]Li J, Qu C, Shao J. Ship detection in SAR images based on an improved faster R-CNN; proceedings of the 2017 SAR in Big Data Era: Models, Methods and Applications (BIGSAR DATA), F, 2017 [C]. IEEE.
- [46]Xia G-S, Bai X, Ding J, et al. DOTA: A large-scale dataset for object detection in aerial images; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2018 [C].
- [47]Huang L, Liu B, Li B, et al. OpenSARShip: A dataset dedicated to Sentinel-1 ship interpretation [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2017, 11(1): 195-208.
- [48]Isola P, Zhu J-Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2017 [C].
- [49]Zhu J-Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks; proceedings of the Proceedings of the IEEE international conference on computer vision, F, 2017 [C].
- [50]Schmitt M, Hughes L H, Zhu X X. The SEN1-2 dataset for deep learning in SAR-optical data fusion [J]. arXiv preprint arXiv:180701569, 2018.
- [51]Wang L, Xu X, Yu Y, et al. SAR-to-optical image translation using supervised cycle-consistent adversarial networks [J]. IEEE Access, 2019, 7: 129136-49.
- [52]Fu S, Xu F, Jin Y-Q. Reciprocal translation between SAR and optical remote sensing images with cascaded-residual adversarial networks [J]. Science China Information

Sciences, 2021, 64(2): 1-15.

[53]Polikar R. Ensemble based systems in decision making [J]. IEEE Circuits and systems magazine, 2006, 6(3): 21-45.

[54]Kuncheva L I. Using measures of similarity and inclusion for multiple classifier fusion by decision templates [J]. Fuzzy sets and systems, 2001, 122(3): 401-7.

[55]Rizvi S A, Nasrabadi N M. Fusion of automatic target recognition algorithms; proceedings of the Automatic Target Recognition XII, F, 2002 [C]. International Society for Optics and Photonics.

[56]Ma W, Guo Q, Wu Y, et al. A Novel Multi-Model Decision Fusion Network for Object Detection in Remote Sensing Images [J]. Remote Sensing, 2019, 11(7).

[57]Bi F, Chen J, Zhuang Y, et al. A Decision Mixture Model-Based Method for Inshore Ship Detection Using High-Resolution Remote Sensing Images [J]. Sensors (Basel), 2017, 17(7).

[58]Huang L, Li W, Chen C, et al. Multiple features learning for ship classification in optical imagery [J]. Multimedia Tools and Applications, 2017, 77(11): 13363-89.

[59]Huan R, Pan Y. Decision fusion strategies for SAR image target recognition [J]. IET Radar, Sonar & Navigation, 2011, 5(7).

[60]Cong T, Yongshun L, Hua Y, et al. Decision-level fusion detection for infrared and visible spectra based on deep learning [J]. Infrared and Laser Engineering, 2019, 48(6): 626001-0626001 (15).

[61]Guo H, Shi Q, Du B, et al. Scene-driven multitask parallel attention network for building extraction in high-resolution remote sensing images [J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(5): 4287-306.

[62]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [Z]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-8.10.1109/cvpr.2016.90

[63]Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation [Z]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.

2019: 3146-54.10.1109/cvpr.2019.00326

[64]Hochreiter S, Schmidhuber J. Long short-term memory [J]. Neural computation, 1997, 9(8): 1735-80.

[65]Zhou F, Hang R, Liu Q, et al. Hyperspectral image classification using spectral-spatial LSTMs [J]. Neurocomputing, 2019, 328: 39-47.

[66]Yin J, Qi C, Chen Q, et al. Spatial-spectral network for hyperspectral image classification: A 3-D CNN and Bi-LSTM framework [J]. Remote Sensing, 2021, 13(12): 2353.

[67]Liu Q, Zhou F, Hang R, et al. Bidirectional-convolutional LSTM based spectral-spatial feature learning for hyperspectral image classification [J]. Remote Sensing, 2017, 9(12): 1330.

[68]Grünthal G. European macroseismic scale 1998 [R]: European Seismological Commission (ESC), 1998.

[69]Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks [Z]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-8.10.48550/arXiv.1608.06993

[70]Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the inception architecture for computer vision [Z]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2818-26.10.1109/cvpr.2016.308

[71]Chollet F. Xception: Deep learning with depthwise separable convolutions [Z]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-8.10.1109/cvpr.2017.195

[72]Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications [J]. arXiv preprint arXiv:1704.04861, 2017.

[73]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [J]. arXiv preprint arXiv:1409.1556, 2014.

[74]Ishraq A, Lima A A, Kabir M M, et al. Assessment of Building Damage on Post-Hurricane Satellite Imagery using improved CNN [Z]. 2022 International Conference on

Decision Aid Sciences and Applications (DASA). IEEE. 2022: 665-9.10.1109/dasa54658.2022.9765025

[75]Choi J, Chun D, Kim H, et al. Gaussian yolov3: An accurate and fast object detector using localization uncertainty for autonomous driving; proceedings of the Proceedings of the IEEE/CVF International Conference on Computer Vision, F, 2019 [C].

[76]Zhu H, Zhou M, Alkins R. Group role assignment via a Kuhn–Munkres algorithm-based solution [J]. IEEE Transactions on Systems, Man, and Cybernetics-Part A: Systems and Humans, 2011, 42(3): 739-50.

[77]Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity [J]. IEEE transactions on image processing, 2004, 13(4): 600-12.